

Institutsleitung
Prof. Dr.-Ing. Dr. h. c. J. Becker (Sprecher)
Prof. Dr.-Ing. E. Sax
Prof. Dr. rer. nat. W. Stork

Bachelorarbeit Nr. ID-3533

von Herrn cand. mach. Tim **Quenzer**

**Exploration unterschiedlicher KI-Modelle zur
objektiven Kaffeearomabestimmung;
Exploration of Different AI Models for
Objective Coffee Aroma Determination**

Beginn: 04.10.2024

Abgabe: 04.04.2025

Betreuer: M. Sc. Markus Lehner
ITIV

Korreferent: Prof. Dr.-Ing. Jürgen Becker
Institut für Technik der Informationsverarbeitung

Hauptreferent: Prof. Dr.rer.nat. Wilhelm Stork

Ich versichere wahrheitsgemäß, die Arbeit selbstständig verfasst, alle benutzten Quellen und Hilfsmittel vollständig und genau angegeben und alles kenntlich gemacht zu haben, was aus Arbeiten anderer unverändert oder mit Abänderungen entnommen wurde, sowie die Satzung des KIT zur Sicherung guter wissenschaftlicher Praxis in der jeweils gültigen Fassung beachtet zu haben.

Karlsruhe, den 27. März 2025

Tim Quenzer

Zusammenfassung

Die sensorische Wahrnehmung von Kaffee ist komplex und basiert auf einer Vielzahl flüchtiger organischer Verbindungen, die das Aroma und den Geschmack prägen. Die Klassifikation von Kaffeearomen erfolgt bislang durch professionelle Verkoster, ein Verfahren, das sowohl subjektiv als auch zeitaufwendig ist. Fortschritte in der Sensortechnologie und im Bereich des maschinellen Lernens eröffnen neue Möglichkeiten für eine objektive und automatisierte Analyse. Eine elektronische Nase (E-Nose) in Kombination mit modernen Machine-Learning-Algorithmen könnte eine präzisere und reproduzierbare Klassifikation von Kaffeearomen ermöglichen.

Diese Arbeit untersucht, inwiefern sich Kaffeesorten anhand ihrer Aromaprofile durch den Einsatz zweier unterschiedlicher Sensortechnologien klassifizieren lassen. Die Sensordaten wurden mit verschiedenen maschinellen Lernverfahren analysiert, darunter überwachtes Lernen (k-Nearest Neighbor, Naïve Bayes), unüberwachtes Lernen (DBSCAN, k-Means) sowie neuronale Netze (LSTM, Feedforward-Netzwerke). Die Klassifikation der Kaffeesorten mittels k-NN und Naïve Bayes zeigte nur für einzelne Sorten zufriedenstellende Ergebnisse, während die Clusteranalyse zwar einige Proben mit ähnlichen Aromen korrekt gruppieren konnte, aber auch zu Fehlzuweisungen führte. Der Einsatz neuronaler Netze erzielte jedoch vielversprechende Ergebnisse, insbesondere bei der Vorhersage einzelner Aromaprofile. Insgesamt verdeutlichen die Ergebnisse das Potenzial von E-Nose-Systemen für die automatisierte Kaffeearoma-Analyse, zeigen jedoch zugleich Herausforderungen in Bezug auf die Datenaufbereitung und die Auswahl geeigneter Modellarchitekturen auf.

Inhaltsverzeichnis

Zusammenfassung	i
1. Einleitung	1
2. Grundlagen	2
2.1. Kaffeearomen	2
2.1.1. Die Chemie der Aromen	2
2.1.2. Ermittlung von Aromen	3
2.2. Die menschliche Aromenerkennung	5
2.2.1. Aufnahme von Duftstoffen	5
2.2.2. Verarbeitung des Signals	5
2.2.3. Weiterverarbeitung im Gehirn	6
2.3. E-Nose	7
2.3.1. Die electronic nose (E-Nose) im Allgemeinen	7
2.3.2. Sensor basierend auf Frequenzänderung	7
2.3.3. Sensor basierend auf Widerstandänderung	8
2.4. Machine Learning	8
2.4.1. Supervised Learning	9
2.4.2. Unsupervised Learning	9
2.5. künstliche Neuronale Netze	11
2.5.1. Das Netz im Allgemeinen	11
2.5.2. Verlust- und Aktivierungsfunktion	12
2.5.3. Training von Netzen	13
2.5.4. Rekurrente Neuronale Netze und LSTM	14
3. Konzept	15
4. Datenvorbereitung	17
4.1. Der benutzte Datensatz	17
4.2. Auswahl der Sensoren und Fehlerkorrektur	19
4.2.1. Auswahl der Sensoren	19
4.2.2. Korrektur der Daten	20
4.3. Normalisieren	21
4.4. Generierung von Trainingsdaten	22
4.5. Data Augmentation	24

5. Datenanalyse und Ergebnisse	26
5.1. Klassifikation von Kaffee	26
5.1.1. K-Nearest-Neighbor	26
5.1.2. Naïve Bayes	27
5.2. Labeling der Kaffees für das Training	28
5.2.1. Labeln des Kaffees in Überkategorien	28
5.2.2. Mapping der Überkategorien auf Hauptaromen	29
5.3. Mustererkennung in den Sensordaten	31
5.3.1. Wieso diese Algorithmen?	31
5.3.2. Ergebnisse der Unsupervised Learning Verfahren	32
5.4. Vorhersage der Aromen	33
5.4.1. Architektur der Netze	34
5.4.2. Ergebnisse der Feedforward Architektur	35
5.4.3. Ergebnisse der LSTM Architektur	36
6. Vergleich mit Smart Nanotubes	38
6.1. Aufnahme neuer Daten	38
6.2. Datenvorbereitung	39
6.3. Vorhersage der Klassifikation	39
6.3.1. kNN	40
6.3.2. Naïve Bayes	40
6.4. Unsupervised Learning	41
6.5. Neuronale Netze	42
7. Ausblick	44
A. Anhang	46
Abkürzungen	47
Symbole	48
Literatur	49

1. Einleitung

Kaffee ist eines der beliebtesten Getränke weltweit und zeichnet sich durch eine außergewöhnliche Vielfalt an Aromen aus. Die sensorische Wahrnehmung von Kaffee erfolgt durch komplexe Wechselwirkungen flüchtiger organischer Verbindungen volatile organische Verbindungen (VOCs)s, die während des Röstprozesses entstehen. Traditionell erfolgt die Klassifizierung von Kaffeearomen durch professionelle Verkoster, die zwar versuchen, eine objektive Einschätzung der Geschmacksprofile zu schmecken, diese ist jedoch in vielen Fällen zumindest teilweise subjektiv. Mit der fortschreitenden Entwicklung von Sensortechnologien und maschinellen Lernverfahren ergeben sich jedoch neue Möglichkeiten zur automatisierten und objektiven Bestimmung von Aromen.

Die zuverlässige und objektive Klassifizierung von Kaffeearomen ist für verschiedene Akteure der Kaffeebranche von Bedeutung, darunter Röstereien, Händler und Konsumenten. Eine E-Nose, kombiniert mit Machine-Learning-Methoden, kann helfen, Kaffeearomen präzise zu identifizieren und geschmackliche Unterschiede zwischen verschiedenen Sorten zu quantifizieren.

Um dieses Ziel zu erreichen, wurden in dieser Arbeit Kaffeearomen mithilfe zweier unterschiedlicher E-Nose-Technologien analysiert. Zur Sicherstellung der Qualität und Vergleichbarkeit der beiden Sensordaten wurden die Rohdaten zunächst gefiltert und normalisiert. Dadurch konnte gewährleistet werden, dass dieselben Algorithmen auf beide Datensätze angewendet und die Ergebnisse direkt miteinander verglichen werden können.

Die Qualität der Messdaten wurde durch den Einsatz verschiedener Supervised-Learning-Algorithmen überprüft, deren Ziel es war, die jeweilige Kaffeesorte vorherzusagen. Hierzu wurden einzelne Messungen aus dem Trainingsdatensatz entfernt und anschließend getestet, ob das Modell die korrekte Kaffeesorte bestimmen kann. Zusätzlich wurde untersucht, ob unüberwachte Lernverfahren in der Lage sind, die Proben entsprechend ihrer Geschmacksprofile – beispielsweise schokoladig oder fruchtig – sinnvoll zu gruppieren.

Die Bestimmung der Kaffeearomen wurde in dieser Arbeit umgesetzt, indem zunächst für jede Kaffeesorte die Intensitäten der grundlegenden Aromen berechnet wurden. Basierend auf diesen Intensitäten wurde ein künstliches neuronales Netz trainiert, wobei einzelne Kaffeesorten aus dem Trainingsdatensatz ausgeschlossen wurden. Diese zuvor nicht gesehenen Proben wurden nach dem Training dem Modell vorgelegt, um zu evaluieren, inwieweit das Netz in der Lage ist, die Aromen unbekannter Kaffees korrekt zu approximieren.

2. Grundlagen

In diesem Kapitel werden die Grundlagen von Kaffeearomen erläutert, die in dieser Arbeit mithilfe von maschinellem Lernen analysiert werden. Darüber hinaus werden die Sensortechnologien, die zur Datenerhebung genutzt werden betrachtet, sowie die Biologie des Menschen zur Erkennung von Aromen.

2.1. Kaffeearomen

2.1.1. Die Chemie der Aromen

Kaffeearomen beziehen sich auf die charakteristischen Düfte, die von gebrühtem Kaffee freigesetzt werden. Diese entstehen durch das komplexe Zusammenspiel VOCs, die hauptsächlich während des Röstprozesses gebildet werden, sowie anorganischer Verbindungen, wie beispielsweise Koffein, die allerdings einen weniger wichtigen Bestandteil zum Aroma beitragen. Bis heute wurden mehr als 800 unterschiedliche organische Verbindungen in Kaffee gefunden.[1][2] Diese Aromen spielen eine entscheidende Rolle im Gesamterlebnis des Kaffeegenusses und beeinflussen maßgeblich die Wahrnehmung von Geschmack, Qualität und Genuss der Konsument:innen.

Die Komplexität der Kaffeearomen entsteht durch verschiedene Faktoren, darunter die Sorte der Kaffeebohne, die geografische Herkunft oder das Terrain, die nach der Ernte angewandten Verarbeitungsmethoden sowie die eingesetzten Rösttechniken. So werden äthiopische Kaffees häufig für ihre fruchtigen und blumigen Aromen geschätzt, im Gegensatz zu den nussigen und schokoladigen Noten brasilianischer Sorten [1].

Die Entstehung von Kaffeearomen wird zudem von den chemischen Reaktionen während des Röstens beeinflusst, einschließlich der Maillard-Reaktion; diese ist eine Reaktion von Aminosäuren und Zuckern, welche Kaffeebohnen die braune Farbe gibt, und der Karamellisierung von Zucker. Diese Prozesse erzeugen eine Vielzahl von VOCs, wie Aldehyde, Ketone und Pyrazine [3][1].

Unterschiedliche Röstgrade führen zu variierenden aromatischen Profilen: Hellere Röstungen betonen oft fruchtigere Noten, während dunklere Röstungen reichere, kräftigere Aromen erzeugen. Die in Kaffee gefundenen VOCs lassen sich in den meisten Fällen in Aromen einteilen, die im Specialty Coffee Association (SCA) Coffee Taster's Flavor Wheel dargestellt werden [1][2][4]. In der nachfolgenden Auflistung ist eine genauere

Darstellung der einzelnen Aromen von Kaffee mit den Verbindungen, die das Aroma erzeugen.

- **Nussig/Kakao:** Dominiert von Pyrazin-, Furan- und Pyrrol-Derivaten, die reichhaltige, nussige Aromen erzeugen.
- **Süß:** Umfasst Aldehyde und Ketone, die süße Noten vermitteln, von fruchtigen bis hin zu zuckerähnlichen Profilen.
- **Floral:** Besteht hauptsächlich aus Alkoholen und Ketonen, die zarte, blumige Düfte liefern.
- **Fruchtig:** Aldehyde, Ketone und Ester, bereichern Kaffee um die meisten fruchtigen Aromen,
- **Sauer/Fermentiert:** Gekennzeichnet durch Säuren, die saure und spritzige Noten hinzufügen.
- **Gewürze:** Hauptsächlich durch Furan-Derivate repräsentiert, die eine würzige Dimension verleihen.
- **Grün/Vegetativ:** Besteht überwiegend aus Verbindungen wie Pyridin und Pyrazin, die frische, grüne Düfte hervorrufen [1].

2.1.2. Ermittlung von Aromen

Die Aromen eines Kaffees werden durch einen Vorgang namens Cupping bestimmt. Hierbei ist der genaue Vorgang von der SCA vorgeschrieben und beinhaltet Vorgaben bezüglich dem Zeitpunkt der Messung, dem Mahlgrad des Kaffees, der Menge an Kaffeepulver für eine gegebene Menge Wasser und der Art des Wassers.[5]

Die eigentliche Bestimmung des Aromas geschieht dann, indem zunächst an den frisch gemahlten Bohnen gerochen wird. Dann wird der Kaffee aufgegossen, wobei nach 3 Minuten die Kruste auf dem Kaffee aufgebrochen wird und nun nochmal gerochen wird. Nachdem der Kaffee nun etwas abgekühlt ist, wird der Kaffee erstmals in den Mund genommen und mit den Dämpfen, die in die Nase aufsteigen der Geschmack und der Nachgeschmack bewertet. Danach werden erst andere Aspekte, wie die Säure, der Körper sowie das Gleichgewicht beurteilt. Bei einer Temperatur, die leicht über der Raumtemperatur ist wird dann noch die Süße beurteilt [5].

2.1.2.1. Werkzeuge zur Aroma-Bewertung

Eines der wichtigsten Werkzeuge für die Bewertung von Aromen ist das Coffee Taster's Flavor Wheel, das zuletzt 2016 von der SCA mithilfe des World Coffee Research Sensory Lexicon überarbeitet wurde. Dieses Aromarad bietet einen strukturierten Rahmen zur Identifizierung und Kategorisierung von Kaffee-Aromen. Hierbei sind, wie man in Abbildung 2.1 sieht, in der Mitte Hauptaromen, welche detaillierter werden, je weiter man nach außen geht. Das allgemeine Vorgehen zum Bestimmen des Aromas funktioniert hierbei so, dass man zunächst ein Hauptaroma durch den Geruch oder den Geschmack entdeckt und dann immer weiter nach außen im Rad geht, um dieses besser zu beschreiben [4].



Abbildung 2.1.: Das Kaffeearoma Rad der SCA [6]

2.2. Die menschliche Aromenerkennung

In diesem Kapitel wird ein Einblick in die menschliche Duftaufnahme und -verarbeitung gegeben, die eine zentrale Rolle für die Aromaerfassung spielt.

2.2.1. Aufnahme von Duftstoffen

Bei jedem Atemzug gelangen Duftmoleküle in die Nasenhöhle. Im oberen Bereich der beiden Nasenhöhlen befindet sich die Riechschleimhaut, die als primäre Interaktionsstelle für Duftstoffe dient. In dieser Schleimhaut sind olfaktorische Rezeptorneuronen (ORN) angesiedelt, von denen es etwa 400 unterschiedliche Typen gibt, die für die Wahrnehmung verschiedener Düfte verantwortlich sind [7, 8].

Sobald ein Geruch aufgenommen wird, erzeugen die ORN ein elektrisches Signal, das durch einen porösen Bereich im Schädel gesendet wird, hier liegen die sogenannten Riechfäden, durch die das elektrische Signal geleitet wird. Das Signal wird anschließend in den Riechkolben (ein vorgestülpter Teil des Gehirns für die Geruchswahrnehmung) übertragen, wo die erste Verarbeitung der Signale aus den ORN erfolgt [8, 9].

2.2.2. Verarbeitung des Signals

Im Riechkolben werden die ankommenden Signale zunächst in den Glomeruli (stark verschaltete Synapsen im Riechkolben) verarbeitet. Dabei findet eine erste Kartierung der Gerüche statt, indem die unterschiedlich starken Signale der ORN als ein Geruch interpretiert werden. Dann werden die verarbeiteten Duftinformationen in höhere Regionen des Gehirns weitergeleitet, wo eine detailliertere Analyse und Interpretation der Gerüche erfolgt. Die Abfolge der Verarbeitung ist in Abbildung 2.2 dargestellt.[8]




Abbildung 2.2.: The human olfactory system [7]. Die Aufnahme und Verarbeitung von Gerüchen in der menschlichen Nase.

2.2.3. Weiterverarbeitung im Gehirn

Von der primären olfaktorischen Rinde werden die Signale an höhere kortikale Areale und das limbische System weitergeleitet. Die kortikalen Areale ermöglichen die bewusste Wahrnehmung von Gerüchen, während das limbische System emotionale Reaktionen, Verhaltensweisen und die Verknüpfung von Gerüchen mit Erinnerungen steuert.[10]

2.3. E-Nose

2.3.1. Die E-Nose im Allgemeinen

Allgemein werden als E-Nose Gassensoren bezeichnet, die nicht auf einzelne Gase reagieren, sondern eine Reihe von Kanälen beinhalten, die auf unterschiedlichste Gase ein entsprechendes Sensorsignal liefern. Hierdurch entsteht für jedes Gas oder jede Gas Mischung ein entsprechender Fingerabdruck, der durch eine Analyse wieder zurückgeführt werden kann. Diese Technologie wurde in den letzten 20 Jahren stark erforscht, sodass inzwischen eine Reihe von unterschiedlichen E-nose Technologien entwickelt wurde und für diverse Aufgaben genutzt werden [11]. So wurde beispielsweise während der Covid-19-Pandemie daran geforscht, wie man mithilfe dieser Technik ohne jegliche Berührung eine Erkrankung feststellen kann [12].

2.3.2. Sensor basierend auf Frequenzänderung

2.3.2.1. Aufbau und Funktionsweise des Sensors

Eine Möglichkeit eine E-Nose zu realisieren, ist die Quartz-Crystal-Microbalance (QCM)-Technologie. Hierbei handelt es sich um eine hochsensitive Methode zur Detektion von Massenänderungen auf einer Quarzoberfläche. Der Sensor besteht aus einem schwingenden Quarzkristall, dessen Resonanzfrequenz sich proportional zur adsorbierten Masse auf seiner Oberfläche ändert [13].

Um die Selektivität des Sensors zu verbessern, wird die Oberfläche des Quarzkristalls mit dünnen Schichten sogenannter surface-mounted Metal-Organic Frameworks (SURMOFs) beschichtet. Diese Metal-Organic Framework (MOF)-Schichten sind hochporös und können spezifische Moleküle aus der Umgebung adsorbieren. Die Adsorption führt zu einer Massezunahme, welche die Resonanzfrequenz des Quarzkristalls verändert. Diese Frequenzverschiebung ist direkt proportional zur Menge der adsorbierten Moleküle und dient als Messsignal [13].

2.3.2.2. Messprinzip und Signalauswertung

Die Funktionsweise des QCM-Sensors basiert auf dem piezoelektrischen Effekt des Quarzkristalls. Wird eine Wechselspannung angelegt, beginnt der Kristall mit der Oberfläche A , der Dichte ρ_q und dem Schermodul μ_q in seiner charakteristischen Resonanzfrequenz f_0 zu schwingen. Kommt es zu einer Massenänderung Δm durch Adsorption von Molekülen an der SURMOFs-Beschichtung, verschiebt sich diese Resonanzfrequenz Δf gemäß der Sauerbrey-Gleichung [13]:

$$\Delta f = -\frac{2f_0^2 \Delta m}{A\sqrt{\rho_q \mu_q}}. \quad (2.1)$$

Durch kontinuierliche Messung der Frequenzverschiebung kann die Adsorption von Zielmolekülen in Echtzeit verfolgt werden.

2.3.3. Sensor basierend auf Widerstandsänderung

Eine weitere Möglichkeit eine E-Nose zu entwickeln, ist auf Basis der Änderung des elektrischen Widerstands. Diese geschieht, in dem hier genutzten Sensor, indem Kohlenstoffnanoröhren ähnlich zu dem QCM Sensor als Schwamm dienen, in dem die Moleküle der Probe aufgefangen werden und eine Veränderung des elektrischen Widerstands verursachen.

Um möglichst viele VOCs zu erkennen, werden hierbei die einzelnen Sensoren leicht verändert, hierdurch entsteht für jede gemessene Probe eine Art Fingerabdruck [14][15].

2.3.3.1. Probenfluss und Messung

Der Sensor verfügt über einen integrierten Lüfter, der den Luftstrom durch das Gerät steuert. Während einer Messung wird die VOCs-Probe durch den Luftstrom über die Sensoren geführt.

Im Anschluss daran wird eine Referenzmessung durchgeführt, bei der der Basiswiderstand (R_0) der Sensoren ohne VOCs-Exposition aufgezeichnet wird. Sobald die Probe auf die Sensoren trifft, wird der Widerstand (R_g) unter VOCs-Exposition gemessen.

Die prozentuale Sensorantwort ?? wird nach folgender Formel berechnet:

$$A_s = \frac{R_g - R_0}{R_0} \times 100 \quad (2.2)$$

Diese Berechnung ermöglicht die Quantifizierung der chemischen Reaktion der Sensoren auf die jeweilige VOCs-Konzentration [15].

2.4. Machine Learning

In diesem Kapitel wird ein Einblick in maschinelles Lernen (Machine Learning) gegeben, es werden allgemeine Ansätze sowie die in dieser Arbeit genutzten Algorithmen näher betrachtet.

Das maschinelle Lernen ist ein Teilgebiet der Künstlichen Intelligenz, das es Systemen ermöglicht, aus Daten zu lernen und Muster zu erkennen, ohne explizit programmiert zu werden. Dabei werden Algorithmen eingesetzt, um Vorhersagen oder Entscheidungen auf Basis von Beispieldaten zu treffen und ihre Leistung durch Erfahrungen zu verbessern.

Es wird sowohl überwachtes als auch unüberwachtes Lernen verwendet. Für die Klassifikation der Kaffeearomen werden die Algorithmen k-Nearest-Neighbor (k-NN), Naïve Bayes und neuronale Netze untersucht. Zur Mustererkennung in den Sensordaten kommen die Clustering-Methoden DBSCAN und k-Means zum Einsatz [16].

2.4.1. Supervised Learning

Beim überwachten Lernen werden Modelle mit gelabelten Daten trainiert, das heißt, jeder Eingabe ist eine bekannte Ausgabe zugeordnet. Typische Algorithmen in diesem Bereich sind Entscheidungsbäume, Support Vector Machines (SVMs) und neuronale Netze. Das Ziel ist es, eine Funktion zu erlernen, die Eingaben auf die korrekten Ausgaben abbildet [16].

2.4.2. Unsupervised Learning

Unüberwachtes Lernen hingegen arbeitet mit nicht gelabelten Daten. Das Modell versucht, Muster und Strukturen in den Daten selbstständig zu identifizieren. Hierzu gehören Clustering-Methoden wie k-Means und hierarchisches Clustering sowie Dimensionalitätsreduktionstechniken wie Principal Component Analysis (PCA) [16].

2.4.2.1. k-Nearest-Neighbors

Der k-NN Algorithmus ist ein instanzbasiertes Verfahren, bei dem neue Datenpunkte basierend auf den k nächstgelegenen Nachbarn klassifiziert werden. Die Klassenzugehörigkeit eines neuen Datenpunkts wird durch Mehrheitsentscheidung der Nachbarn bestimmt. Die Distanz d zwischen zwei Datenpunkten x und y wird im n -dimensionalen Raum üblicherweise mit der euklidischen Metrik berechnet:

$$d(x, y) = \sqrt{\sum_{i=1}^n (x_i - y_i)^2}. \quad (2.3)$$

Darüber hinaus wird in dieser Arbeit der k-NN so verwendet, dass nähere Nachbarn stärker gewichtet in die Klassifikation einfließen.[17] Ein wesentlicher Vorteil von k-NN ist, dass er keine Annahmen über die Verteilung der Daten erfordert, was ihn flexibel für nichtlineare Zusammenhänge macht. Besonders bei kleinen Datensätzen kann dies von Vorteil sein, da keine komplexe Modellanpassung notwendig ist. Allerdings bringt k-NN auch einige Herausforderungen mit sich. Ein Hauptproblem ist seine Empfindlichkeit gegenüber

Rauschen und Messfehlern, da jeder einzelne Datenpunkt direkt in die Klassifikation einfließt. Zudem kann die Wahl des Parameters k einen erheblichen Einfluss auf die Genauigkeit haben. Ein zu kleines k kann zu einer hohen Varianz führen, während ein zu großes k die individuellen Merkmale der Kaffeesorten nicht mehr eindeutig beschreibt [17].

2.4.2.2. Naïve Bayes

Naïve Bayes basiert auf dem Bayes-Theorem und nimmt an, dass alle Merkmale unabhängig voneinander sind. Die Klassenzuweisung erfolgt durch Berechnung der bedingten Wahrscheinlichkeit für jede mögliche Klasse C_k gegeben die Merkmale $x_1, x_2, \dots, x_n$:

$$P(C_k|X) = \frac{P(X|C_k)P(C_k)}{P(X)}. \quad (2.4)$$

Hierbei wird $P(X|C_k)$ als das Produkt der Einzelwahrscheinlichkeiten der Merkmale angenommen [18]. Vorteile dieses Algorithmus sind seine Effizienz und die gute Generalisierungsfähigkeit bei kleinen Datensätzen. Wenn die Unabhängigkeitsannahme jedoch nicht erfüllt ist wird dieser Algorithmus instabiler und die Genauigkeit der Vorhersage sinkt.

2.4.2.3. DBSCAN

Der Density-Based Spatial Clustering of Applications with Noise (DBSCAN) Algorithmus gruppiert Datenpunkte basierend auf ihrer Dichte. Er definiert Cluster als Regionen mit hoher Punktedichte, während spärlich besetzte Bereiche als Rauschen betrachtet werden. Ein Punkt p wird als Kernpunkt eines Clusters betrachtet, wenn er mindestens eine Anzahl ϵ weiterer Punkte innerhalb eines Radius δ besitzt:

$$N_\delta(p) = \{q \in D | d(p, q) \leq \delta\}, \quad \text{wenn } |N_\epsilon(p)| \geq \epsilon. \quad (2.5)$$

Vorteile von DBSCAN sind seine Fähigkeit, Cluster beliebiger Form zu erkennen und seine Robustheit gegenüber Ausreißern. Nachteile sind die Abhängigkeit von den Parametern ϵ und δ , die je nach Datensatz angepasst werden müssen [19][20].

2.4.2.4. k-Means

Der k-Means Algorithmus ist ein partitionierendes Clustering-Verfahren, das die Daten in k Gruppen aufteilt. Der Algorithmus beginnt mit k zufällig gewählten Zentroiden und weist jedem Punkt x das nächste Zentrum c_i zu

$$\arg \min_{c_i} d(x, c_i). \quad (2.6)$$

Nach jeder Iteration werden die Zentroiden neu berechnet als der Mittelwert aller Punkte im Cluster:

$$c_i = \frac{1}{|C_i|} \sum_{x \in C_i} x. \quad (2.7)$$

Vorteile sind seine einfache Implementierung und Effizienz für große Datensätze. Nachteile sind seine Anfälligkeit für Ausreißer und die Notwendigkeit, k im Voraus festzulegen [21].

2.5. künstliche Neuronale Netze

In diesem Kapitel werden künstliche neuronale Netze erklärt, hierfür wird untersucht, wie ein neuronales Netz im Allgemeinen funktioniert. Außerdem wird das Training betrachtet sowie die in dieser Arbeit genutzten Architekturen.

2.5.1. Das Netz im Allgemeinen

künstliche Neuronale Netze orientieren sich an der Funktionsweise biologischer neuronaler Netze und bestehen aus einer Vielzahl vernetzter künstlicher Neuronen. Ein künstliches Neuron ist die fundamentale Verarbeitungseinheit eines neuronalen Netzes. Es modelliert die Arbeitsweise biologischer Neuronen und führt eine gewichtete Summe seiner Eingaben aus, die anschließend durch eine Aktivierungsfunktion transformiert wird [16]. Mathematisch kann ein Neuron folgendermaßen beschrieben werden:

$$y = f\left(\sum_{i=1}^n w_i x_i + b\right), \quad (2.8)$$

wobei x_i die Eingaben, w_i die zugehörigen Gewichte und b der Bias ist [22][23].

Neuronale Netze sind hierarchisch in Schichten organisiert, wie es in Abbildung 2.3 zu sehen ist. Die erste Schicht, die sogenannte Eingabeschicht, nimmt die Eingabedaten entgegen und reicht sie an die nächste Schicht weiter. Anschließend folgen eine oder mehrere verborgene Schichten (Hidden Layers), die die eigentliche Verarbeitung der Daten übernehmen. Diese bestehen aus Neuronen, die die Eingaben durch gewichtete Transformationen (Aktivierungsfunktionen) weiterverarbeiten. Die Anzahl der verborgenen Schichten sowie die Anzahl der Neuronen pro Schicht beeinflussen die Modellkapazität und somit die Fähigkeit des Netzes, komplexe Zusammenhänge zu erlernen. Schließlich existiert die Ausgabeschicht, die das Endergebnis der Berechnungen liefert. Diese kann je nach Anwendung eine Klassenzuweisung oder eine numerische Schätzung ausgeben. Die Verarbeitung in einem neuronalen Netz erfolgt durch den sogenannten Vorwärtsdurchlauf (Forward Propagation). Dabei werden die Eingabedaten durch die Netzwerkarchitektur propagiert, wobei jede Schicht ihre spezifischen Transformationen durchführt. Nach




Abbildung 2.3.: Aufbau eines künstlichen neuronalen Netzes [24]

diesem Durchlauf wird die Ausgabe des Netzes mit der tatsächlichen Zielvariable verglichen. Anhand dieser Fehlermessung erfolgt anschließend die Rückwärtspropagation (Backpropagation), bei der die Gradienten der Fehlerfunktion durch das Netz rückwärts propagiert werden. Ziel dieses Prozesses ist es, die Gewichte durch Optimierungsverfahren wie den Gradientenabstieg oder den Adam-Optimierer anzupassen, um den Fehler zu minimieren und die Netzwerkleistung zu verbessern [22][23].

Die Wahl der Netzwerkarchitektur hängt stark von der jeweiligen Aufgabe ab. Flache Netze, die aus wenigen Schichten bestehen, eignen sich für einfache Mustererkennungsprobleme. Tiefe neuronale Netze (Deep Neural Network (DNN)s) hingegen enthalten viele verborgene Schichten und sind notwendig für die Verarbeitung komplexer Muster und hochdimensionaler Daten. Zusätzlich existieren spezialisierte Architekturen wie Convolutional Neural Network (CNN), die insbesondere in der Bildverarbeitung Anwendung finden [22][23].

Durch diese hierarchische Struktur sind neuronale Netze in der Lage, hochdimensionale Daten effektiv zu verarbeiten und komplexe Zusammenhänge zu erlernen. Die Kombination aus geeigneter Architektur und effizienten Optimierungsmethoden ermöglicht es diesen Netzen, anspruchsvolle Probleme aus unterschiedlichsten Domänen zu lösen [22][23].

2.5.2. Verlust- und Aktivierungsfunktion

In neuronalen Netzen spielen Verlust- und Aktivierungsfunktionen eine zentrale Rolle für das Lernen und die Modellleistung. Während Aktivierungsfunktionen die nichtlinearen Transformationen der Neuronenausgaben bestimmen, messen Verlustfunktionen die Differenz zwischen der vorhergesagten und der tatsächlichen Ausgabe [23].

Eine Aktivierungsfunktion ist notwendig, um komplexe Muster zu erlernen, da sie es dem Netz ermöglicht, nichtlineare Abbildungen der Eingabedaten zu erzeugen. Gängige Aktivierungsfunktionen sind:

- **Sigmoid-Funktion:** Definiert als $\sigma(x) = \frac{1}{1+e^{-x}}$, komprimiert sie die Werte in den Bereich $[0, 1]$ und wird häufig für binäre Klassifikationen verwendet.
- **ReLU (Rectified Linear Unit):** Definiert als $f(x) = \max(0, x)$, sorgt sie für eine sparsame Aktivierung, da negative Werte auf Null gesetzt werden. Sie wird häufig in tiefen neuronalen Netzen eingesetzt.
- **Tangens-Hyperbolicus-Funktion (tanh):** Sie transformiert Werte in den Bereich $[-1, 1]$ und wird oft in rekurrenten Netzen genutzt.

Die Verlustfunktion hingegen gibt an, wie gut oder schlecht das Netz die Zielwerte vorhersagt. Sie dient als Grundlage für das Training, da der Gradientenabstieg versucht, die Verluste zu minimieren. Zu den häufig verwendeten Verlustfunktionen gehören:

- **Mittlerer quadratischer Fehler (Mean Square Error (MSE)):** Wird für Regressionsprobleme genutzt und ist definiert als:

$$\text{MSE} = \frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2. \quad (2.9)$$

- **Kreuzentropieverlust:** Wird bei Klassifikationsproblemen verwendet und berechnet den Fehler basierend auf der Wahrscheinlichkeitsausgabe eines neuronalen Netzes:

$$H(p, q) = - \sum_i p_i \log(q_i). \quad (2.10)$$

Die Wahl der richtigen Aktivierungs- und Verlustfunktion hängt stark von der Art des Problems und der Struktur des Netzes ab. Während Aktivierungsfunktionen bestimmen, wie Informationen durch das Netz fließen, beeinflusst die Verlustfunktion maßgeblich die Konvergenz und Stabilität des Trainingsprozesses [23].

2.5.3. Training von Netzen

Das Training neuronaler Netze ist ein iterativer Optimierungsprozess, der darauf abzielt, die Gewichte des Netzes so anzupassen, dass die Fehlerfunktion minimiert wird. Dabei kommen Algorithmen wie der Gradientenabstieg zum Einsatz, um die Gewichte schrittweise zu aktualisieren.

Ein wichtiger Bestandteil des Trainings ist das sogenannte Batch-Learning, bei dem die Trainingsdaten in kleinere Batches (kleinere Teilmengen der Trainingsdaten) unterteilt werden, um die Effizienz zu steigern und die Konvergenz zu verbessern. Während das gesamte Dataset für den klassischen Gradientenabstieg genutzt wird, verwenden Verfahren wie der Mini-Batch-Gradientenabstieg kleinere Teilmengen der Daten, um schneller zu konvergieren.

Um Überanpassung (Overfitting) zu vermeiden, werden Regularisierungstechniken wie das Dropout-Verfahren eingesetzt. Beim Dropout werden während des Trainings zufällig ausgewählte Neuronen mit einer bestimmten Wahrscheinlichkeit deaktiviert, sodass das Netzwerk gezwungen wird, robustere Merkmale zu lernen.

Zusätzlich können Verfahren wie die L2-Regularisierung (Gewichtsnorm-Strafterm) oder die Dataaugmentation angewendet werden, um die Generalisierungsfähigkeit des Netzes zu erhöhen. Die Kombination dieser Techniken ermöglicht es neuronalen Netzen, stabile und leistungsfähige Modelle zu entwickeln, die auch auf unbekannten Daten gut funktionieren [22][23].

2.5.4. Rekurrente Neuronale Netze und LSTM

Rekurrente neuronale Netze (RNN) sind eine Erweiterung der klassischen neuronalen Netze, die speziell für die Verarbeitung sequenzieller Daten entwickelt wurden. Im Gegensatz zu Feedforward-Netzen besitzen RNNs Rückkopplungsschleifen, die es ermöglichen, Informationen über frühere Zeitschritte hinweg zu speichern und zu nutzen. Dadurch eignen sie sich besonders für Anwendungen wie Sprachverarbeitung, Zeitreihenanalyse und maschinelle Übersetzung.

Mathematisch wird ein RNN durch die folgende rekursive Gleichung beschrieben:

$$h_t = f(W_h h_{t-1} + W_x x_t + b), \quad (2.11)$$

wobei h_t der versteckte Zustand zum Zeitpunkt t ist, x_t die Eingabe, W_h und W_x die Gewichtungsmatrizen und b der Bias.

Ein Problem klassischer RNNs ist der vanishing-gradient-Effekt, bei dem die Gradienten während der Rückpropagation extrem klein werden, was das Lernen über lange Abhängigkeiten erschwert. Long short-term memory (LSTM)-Netzwerke wurden entwickelt, um dieses Problem zu lösen. LSTMs enthalten spezielle Speicherzellen mit drei Toren: Eingangs-, Ausgangs- und Vergessenstor. Diese regulieren den Informationsfluss und ermöglichen eine effiziente Speicherung über lange Zeiträume.

Durch ihre Fähigkeit, langfristige Abhängigkeiten zu lernen, sind LSTMs ein essenzieller Bestandteil moderner künstliche Intelligenz (KI)-Anwendungen, insbesondere in der Verarbeitung natürlicher Sprache und der prädiktiven Modellierung [23][25].

3. Konzept

In diesem Kapitel wird das methodische Vorgehen zur objektiven Bestimmung von Kaffeearomen erläutert. Ziel ist es, mithilfe von E-Nose-Technologien und Machine-Learning-Verfahren die menschliche Nase sowie die Aromenverarbeitung im Gehirn zu imitieren.

Es lassen sich verschiedene Parallelen zwischen der menschlichen und der maschinellen Aromaerkennung erkennen, die in Abbildung 3.1 veranschaulicht sind. Während die Riechrezeptorneuronen der menschlichen Nase VOCs wahrnehmen, erfolgt die sensorische Erfassung in der E-Nose über eine Vielzahl einzelner Sensorkanäle. Anschließend werden die aufgenommenen Signale bei beiden Systemen weiterverarbeitet: Im menschlichen Körper werden sie in elektrische Impulse umgewandelt und an den Riechkolben weitergeleitet, während bei der E-Nose eine Vorverarbeitung der Messdaten erfolgt. Dies umfasst die Reduktion von Rauschen und Messfehlern sowie die Transformation der Daten in Merkmalsvektoren, die für das Training von Machine-Learning-Algorithmen genutzt werden.

Bevor eine detaillierte Analyse einzelner Aromen erfolgen kann, wurde zunächst die Qualität der Messungen sowie der Datenvorverarbeitung untersucht. Dazu kamen verschiedene Verfahren des Supervised und unsupervised Learnings zum Einsatz. Klassifikationsalgorithmen wurden verwendet, um zu überprüfen, ob sich die verschiedenen Kaffeesorten voneinander unterscheiden lassen. Zusätzlich wurden Clustering-Methoden angewandt, um die Messdaten basierend auf ihren geschmacklichen Eigenschaften zu gruppieren. Die Grundlage hierfür bildete eine Analyse der untersuchten Kaffeesorten und ihrer Hauptaromen, die gemäß dem Kaffeearomarat (Abbildung 2.1) kategorisiert wurden.

Die eigentliche Aromenanalyse wurde in dieser Arbeit durch den Einsatz künstlicher neuronaler Netze realisiert, die die Signalverarbeitung im menschlichen Riechkolben nachbilden. Die Netze wurden mit den vorverarbeiteten Daten trainiert, wobei die Hauptaromen der jeweiligen Proben als Zielvektor dienten. Zur Evaluierung der Modellgeneralität wurden bestimmte Kaffeesorten vollständig aus dem Trainingsdatensatz entfernt und ausschließlich für die Testphase verwendet. Damit sollte sichergestellt werden, dass das Modell nicht nur einzelne Proben auswendig lernt, sondern in der Lage ist, unbekannte Strukturen korrekt zu klassifizieren.

Um die Qualität der Datenvorverarbeitung weiter zu validieren, wurde zusätzlich ein LSTM-Netz getestet. Dieses erhielt ausschließlich die gefilterten und normalisierten Rohmessdaten und versuchte, die Aromen der Kaffeesorten ebenfalls zu identifizieren.

Die Hypothese war, dass das zuvor trainierte künstliche neuronale Netz mindestens eine gleichwertige, wenn nicht sogar bessere Leistung erzielt, sofern die Vorverarbeitung der Daten korrekt durchgeführt wurde. Der alleinige Einsatz von LSTM-Netzen wurde jedoch vermieden, da Messfehler und Rauschen unkontrolliert in die Trainingsdaten einfließen könnten, was die Ergebnisse beeinträchtigen und zu einer erhöhten Variabilität führen würde.




Abbildung 3.1.: Gegenüberstellung der menschlichen und maschinellen Erkennung von Gerüchen

4. Datenvorbereitung

In diesem Kapitel wird ein Einblick in die existierenden Daten und die darauf basierende Datenvorverarbeitung gegeben. Dies beinhaltet die Wahl der genutzten Kanäle des Sensors, die Korrektur von Fehlern in den Messungen, die Normierung der Messungen und die Merkmalgenerierung aus den Sensordaten.

4.1. Der benutzte Datensatz

Der vorliegende Datensatz wurde im Rahmen einer vorhergehenden Masterarbeit erstellt und umfasst 16 verschiedene Kaffeesorten, die in drei unterschiedlichen Zuständen analysiert wurden: ganze Bohnen, gemahlene Bohnen und kaltgebrühter Kaffee. Allerdings erwies sich der Datensatz des kaltgebrühten Kaffees als stark fehlerbehaftet, sodass er für die weitere Analyse ausgeschlossen wurde.

Zudem zeigte eine detaillierte Untersuchung, dass die Messdaten von ganzen und gemahlenen Bohnen nicht miteinander kombiniert werden können, da selbst für denselben Kaffee erhebliche Unterschiede in den Sensordaten auftraten, abhängig davon, in welcher Form die Bohne analysiert wurde. Aufgrund dieser Diskrepanz fiel die Wahl letztendlich auf den Datensatz der gemahlenen Bohnen. Diese Entscheidung basiert auch darauf, dass beim Cupping – wie in den Grundlagen bereits erläutert – ebenfalls die gemahlene Bohne und nicht die ganze Bohne zur Beurteilung der Aromen herangezogen wird. So gab es für jede Probe jeweils zwei bis drei Messungen mithilfe eines frequenzbasierten Sensorarrays, wie er in Kapitel 2.3.2 beschrieben wird.

Das Sensorarray besteht aus 32 unterschiedlichen Sensoren. Eine Messung von gemahlenen Bohnen ist in Abb 4.1 exemplarisch dargestellt. Es ist deutlich zu erkennen, dass nicht alle Sensoren einwandfrei funktioniert haben und starken Schwankungen unterliegen. Daher ist eine gründliche Vorverarbeitung der Daten notwendig, bei welcher auch eine gezielte Auswahl der Sensoren geschieht, um die Qualität und Aussagekraft der Messdaten zu sichern.

Wird auf den Einsatz dieser Sensoren verzichtet, lassen sich anhand der Sensorkurven, wie sie in Abbildung 4.2 dargestellt sind, die einzelnen Phasen des Messvorgangs identifizieren. Zunächst wird der Sensor dem Kaffee ausgesetzt, was durch die sinkende Frequenz der Sensoren ersichtlich wird, wie sie gemäß Gleichung 2.1 beschrieben ist. Da die Frequenzänderung mit der Zeit immer geringer wird, weist dies auf eine Sättigung

der Sensoren mit den Kaffeekomponenten hin. In der darauffolgenden Phase, in der Sensoren und Kaffee voneinander getrennt werden, steigen die Sensorkurven erneut an und es entsteht wiederum eine Sättigung des Sensors mit Luft. Dieser Abschnitt des Messvorgangs beschreibt somit die Sättigung des Sensors mit Luft sowie die Reinigung von Kaffee-Rückständen.

Eine genaue Auflistung der in den Messungen genutzten Kaffeesorten ist in Tabelle 4.1.

Tabelle 4.1.: Übersicht der Kaffeesorten

#	Kaffeesorte	Aromen
1	Karma&Co	Dunkle Schokoladenmousse, Nusskrokant
2	La Cristalina	Orangenschale, Aprikose, Pflaumenwein
3	Candy	Apfelwein, rote Früchte
4	Las Alegrias	Aprikose, gelber Pfirsich, süß wie Zucker
5	Mexico kiskadee	Schokolade, Pekannuss, Apfelkuchen
6	Fazenda Matão	Schokoladencreme, Haselnuss, Karamell
7	Willy Wonka	Trinkschokolade, Amarenakirsche
8	Liberica, Honey!	Zuckerwatte, exotische Früchte, verrückt
9	Kenia Crossroads	Dunkle Schokolade, Cassis, dunkler Karamell
10	Wildblume	Geröstete Haselnüsse, Waldhonig, Nougat
11	Berlin, Peru	Schokoladen-Ganache, Himbeere, Zuckerrohr
12	Karma&Co	Schokoladenmousse, Karamell, Orangengelee
13	Rocko Mountain	Erdbeeren, Honigmelone, blumig
14	Ruanda Gisheke	Honigmelone, Fruchtgummi-Apfelringe
15	ALIANÇA	Karamell, Schokolade, Nüsse
16	NENSEBO	Ananas, grüner Apfel, Lakritz




Abbildung 4.1.: Auszug aus den Rohdaten mit allen Sensoren




Abbildung 4.2.: Auszug aus den Rohdaten mit ausgewählten Sensoren.

4.2. Auswahl der Sensoren und Fehlerkorrektur

Das Filtern von Sensordaten dient dazu, Messfehler, Rauschen und ungewollte Schwankungen aus den Daten zu entfernen. Solche Störungen treten in der Sensorik häufig aufgrund von Umwelteinflüssen, technischen Einschränkungen oder fehlerhaften Sensoren auf. Ziel des Filterprozesses ist es, die Datenqualität zu verbessern und sicherzustellen, dass die verarbeiteten Messwerte die tatsächlichen Eigenschaften des beobachteten Systems möglichst genau widerspiegeln.

Typische Fehler in Sensordaten lassen sich in folgende Kategorien einteilen:

- **Kurze Ausreißer:** Einzelne Messwerte oder kurze Messfehler, die aufgrund temporärer Störungen von den übrigen Messungen abweichen und maximal 5% der eigentlichen Messdauer nicht überschreiten.
- **Dauerhafte Fehler:** Sensoren, die dauerhaft fehlerhafte oder unbrauchbare Messwerte liefern, beispielsweise durch Defekte oder Kalibrierungsfehler.
- **Rauschen:** Zufällige kleine Schwankungen in den Messwerten, die keinen Bezug zur tatsächlichen Messgröße haben.

4.2.1. Auswahl der Sensoren

Da ab einer bestimmten Fehlerdichte die Messwerte keine aussagekräftigen Informationen mehr beinhalten, musste eine Selektion der korrekt funktionierenden Sensoren erfolgen. Hierfür wurden die Sensorkurven analysiert, um Fehler und Auffälligkeiten in den Daten zu identifizieren. Zunächst wurde ein Fenster über die Messdaten gelegt, das einen Wertebereich auf der y-Achse von 100 bis - 600 umfasste. Dieses Fenster diente dazu,

die Anzahl der Messpunkte zu bestimmen, die außerhalb dieses Bereichs liegen. Zudem wurde die Beziehung aufeinanderfolgender Messwerte analysiert. Hierbei wurde überprüft, ob eine Frequenzdifferenz Δf von mehr als 5 Hz ist und anschließend, ob er mehr als das 1,5-Fache des vorherigen Wertes beträgt. Falls diese Bedingung erfüllt war, wurde weiter geprüft, ob der nächste Wert ebenfalls diese Kriterien erfüllt, bis die Werte wieder innerhalb der definierten Grenzen liegen. Auch hier wurden diese Messwerte gezählt und als Ausreißer markiert.

Eine Sensorkurve wird als gut markiert, wenn mehr als 90 % der Messpunkte als fehlerfrei erkannt werden. Sensoren, bei denen mehr als 80 % der Kurven als gut bewertet wurden, wurden in den finalen Datensatz aufgenommen.

4.2.2. Korrektur der Daten

Zur Korrektur der Messfehler werden zunächst die identifizierten Fehler ausgeglichen, indem der Messwert vor und nach dem fehlerhaften Bereich durch eine Gerade verbunden wird. Anschließend wird ein Moving Average-Filter auf die Daten angewendet. Dieser funktioniert, indem er aufgrund der vorherigen Messpunkte den aktuellen Messpunkt berechnet und dadurch Rauschen in den Messungen reduziert und kleine Messfehler entfernt [26].

In Abbildung 4.3 ist eine nicht korrigierte Messung eines Channels des QCM Sensors dargestellt und in Abbildung 4.4 dieselbe Kurve nach der Korrektur dargestellt. Der lineare Abschnitt zeigt die Interpolation des fehlerhaften Bereichs, während die insgesamt geglättete Kurve die Effektivität des Moving Average-Filters zur Rauschreduzierung verdeutlicht.




Abbildung 4.3.: Nicht korrigierte Messung eines Channels des QCM Sensors.




Abbildung 4.4.: Korrigierte Messung eines Channels des QCM Sensors.

4.3. Normalisieren

Die Normalisierung gefilterter Sensordaten dient dazu, die Wertebereiche der Messdaten in ein einheitliches Format zu überführen und die Daten für maschinelle Lernverfahren vorzubereiten. Da Sensorwerte durch unterschiedliche Sensortechniken (hier frequenzbasierte und widerstandsbasierte Sensoren) und Einheiten variieren, jedoch das Messverfahren dasselbe ist, stellt die Normalisierung sicher, dass alle Daten gleichmäßig gewichtet und vergleichbar sind. Außerdem können so dieselben Analysetechniken auf beide Datensätze angewendet werden. Die hier eingesetzten Schritte zur Normalisierung umfassen:

- **Offset-Korrektur:** Um sicherzustellen, dass alle Messkurven auf einem gemeinsamen Nullpunkt starten, wird der Offset jeder Kurve entfernt. Dies geschieht, indem der erste Messwert oder ein berechneter Basiswert von allen weiteren Messungen subtrahiert wird.
- **Min-Max-Normierung:** Die Daten werden skaliert, sodass ihre Werte im Bereich von 0 bis 5 liegen. Hierbei wird eine Messung x_i mit

$$x_i = \begin{pmatrix} x_{i,0} \\ x_{i,1} \\ \vdots \\ x_{i,j} \end{pmatrix},$$

wobei die Werte 0 bis j die einzelnen Channel eines Sensors darstellen normiert. Die Relative Größe der Channel zueinander soll außerdem beibehalten werden. Um dies zu erreichen wird der Maximalwert eines Channels j relativ zu dem der gesamten

Messung i betrachtet. Die gesamte Gleichung für die Normierung ergibt sich also zu:

$$x'_{i,j} = 5 \frac{\max(x_{i,j})}{\max(x_i)} \frac{x_{i,j} - \min(x_{i,j})}{\max(x_{i,j}) - \min(x_{i,j})}. \quad (4.1)$$

- **Spiegelung der Daten:** Um eine einheitliche Darstellung der Daten zu gewährleisten, müssen die Kurven einer bestimmten Sensortechnologie gespiegelt werden. Dies ergibt sich aus der Tatsache, dass gemäß Gleichung 2.1 die Frequenz sinkt, wenn die Gase des Kaffees adsorbiert werden, während der Widerstand gemäß Gleichung 2.2 ansteigt. Durch die Spiegelung bleibt die Form der Kurve unverändert, sodass eine konsistente Darstellung gewährleistet ist. Um dies zu gewährleisten wird die Sensorkurve des QCM Sensors an der x-Achse gespiegelt.

In Abbildung 4.5 ist eine Messung nach der Normierung zu sehen.




Abbildung 4.5.: Gefilterte und normierte Sensorkurve

4.4. Generierung von Trainingsdaten

Die Generierung aussagekräftiger Merkmale aus Sensordatenkurven stellt einen entscheidenden Schritt für die erfolgreiche Anwendung von Machine-Learning-Algorithmen dar. Ziel dieses Prozesses ist es, die komplexen Kurvenverläufe der Sensordaten so genau und gleichzeitig so kurz wie möglich durch Merkmalsvektoren zu beschreiben.

Zu den typischen Merkmalen, die hierfür verwendet werden, zählen unter anderem der maximale bzw. minimale Messwerte. Darüber hinaus werden Parameter verwendet, die die Funktionen zur Beschreibung der Kurvenverläufe repräsentieren. Diese Kurvenparameter wurden mithilfe der `curve_fit`-Funktion von `scipy` gefunden, welche iterativ Parameter testet, die eine Kurve nach einer gegebenen Funktion beschreiben. Hierbei wird mit jeder Iteration versucht, die Differenz zwischen approximierter Kurve und Messwerten zu

minimieren. Hierbei wurden allgemein exponentielle Funktionen zur Approximation der Kurvenverläufe getestet, da eine Sättigung in der Physik allgemein eine streng monoton fallende exponentielle Funktion ist. Eine mit dieser Methode genutzte Funktion in dieser Arbeit ist die folgende Exponentialfunktion:

$$f(x) = p_0 \cdot e^{p_1 \cdot x + p_2} + p_3, \quad (4.2)$$

wobei die Parameter p_0 , p_1 , p_2 und p_3 als zusätzliche Merkmale für das Training bereitgestellt werden. Da diese Formel für positive p_i nicht den ansteigenden Teil der Messung in Abbildung 4.6 beschreiben kann wurde für den zweiten Teil der Kurve die Funktion $-f(x)$ verwendet. Um eine noch genauere Approximation der Kurven zu erreichen, wurde zusätzlich die folgende Funktion getestet:

$$f_1(x) = e^{p_0 + p_1 \cdot x + p_2 \cdot x^2 + p_3 \cdot x^3} + p_4, \quad (4.3)$$

Diese Funktion ermöglicht zwar eine präzisere Anpassung an die Sensordaten, entspricht jedoch nicht den charakteristischen Eigenschaften einer klassischen Sättigungskurve. Dies wird auch in Abbildung 4.7 deutlich: Die approximierte Kurve liegt zwar näher an den Messwerten, jedoch führt die zusätzliche Parametrisierung zur Entstehung eines Sattelpunktes, der anschließend wieder verschwindet. Da dieses Phänomen nicht mit einfachen Sättigungsformeln erklärbar war und eine Überanpassung vermieden werden sollte, wurde dieser Ansatz verworfen.




Abbildung 4.6.: Approximierte Kurve nach Formel 4.2




Abbildung 4.7.: Approximierte Kurve nach Formel 4.3

4.5. Data Augmentation

Da die ursprüngliche Datenmenge von 41 Datenpunkten für die meisten Machine-Learning-Algorithmen nicht ausreicht, um eine zuverlässige Vorhersage nach dem Training zu ermöglichen, war es notwendig, zusätzliche Datenpunkte zu generieren. Als Datenpunkt wird hier der Merkmalsarray einer Messung bezeichnet, dieser beinhaltet die Werte p_i aus der Formel 4.2 für jeden Sensor, sowie den Maximalwert der Messung. Um neue Datenpunkte zu erzeugen wurde ein Interpolationsverfahren angewendet, dass einen Mittelwert für jedes Merkmal des zuvor erzeugten Merkmalsvektors zwischen zwei Datenpunkten derselben Klasse erzeugt. Die zugrunde liegende Formel lautet:

$$\mathbf{I} = \mathbf{A} + x(\mathbf{B} - \mathbf{A}), \quad x \in [0, 1], \quad \mathbf{A}, \mathbf{B} \in \mathbb{R}^n \quad (4.4)$$

wobei $\mathbf{A}$ und $\mathbf{B}$ zwei Datenpunkte darstellen und x beschreibt, welcher Punkt stärker gewichtet wird. Mithilfe dieser Methode wurden die Datenpunkte innerhalb einer Kaffeesorte interpoliert, um eine dichtere Datenbasis zu erzeugen. Zusätzlich wurde weißes Rauschen auf den resultierenden Vektor $\mathbf{I}$ addiert, um zu verhindern, dass das System lediglich lineare Zusammenhänge zwischen den Kurven erlernt. Dieses Vorgehen trägt dazu bei, die Vielfalt der Daten zu erhöhen und die Robustheit des Machine-Learning-Modells zu verbessern. In Abbildung 4.8 ist dargestellt, wie eine solche Interpolation der Kurvenparameter bei der Formel 4.3 neue Kurven generiert.

Ein bekanntes Problem dieser Methode besteht darin, dass der Algorithmus ausschließlich konvexe Räume füllen kann, da neue Datenpunkte durch eine Linearkombination bestehender Messwerte erzeugt werden. Dadurch wird jeder Raum in einen konvexen Raum überführt, selbst wenn dies zuvor nicht der Fall war. Da jedoch neue Datenpunkte

ausschließlich aus zwei Messwerten desselben Kaffees generiert wurden, wird angenommen, dass nicht nur jede einzelne Messung eines Kaffees einen gültigen Datenpunkt darstellt, sondern auch jede Kombination der extrahierten Merkmale. Dennoch sollte berücksichtigt werden, dass eine unzureichende Repräsentation des Kaffees durch die gewählten Merkmale dazu führen kann, dass die Interpolation die Erkennung des Kaffees oder seiner Aromen negativ beeinflusst.




Abbildung 4.8.: Interpolierte Kurven mit 5 Interpolationen

5. Datenanalyse und Ergebnisse

In diesem Kapitel wird die vorverarbeitete Datenbasis analysiert. Zunächst wird die Qualität der Datenaufbereitung überprüft, indem eine Klassifikation der Kaffeesorten mithilfe von zwei Supervised Learning-Verfahren (k-NN und Naïve Bayes) durchgeführt wird. Anschließend werden mithilfe von Unsupervised Learning-Verfahren weitere Muster und Strukturen in den Daten identifiziert. Abschließend wird ein detaillierter Einblick in die Architektur der verwendeten neuronalen Netze gegeben, die zur Vorhersage der Aromen eingesetzt wurden.

5.1. Klassifikation von Kaffee

Zur Bewertung der Datenvorverarbeitung werden in diesem Abschnitt zwei unterschiedliche Ansätze des Supervised Learnings untersucht. Durch den Vergleich beider Methoden lassen sich potenzielle Fehlerquellen identifizieren und mögliche Abweichungen in der Klassifikation gezielt analysieren. Dies ermöglicht eine fundierte Bewertung der Datenqualität sowie der Effektivität der Vorverarbeitungsschritte. Um die Ergebnisse der Algorithmen nicht zu verfälschen, wurden außerdem ausschließlich die Trainingsdaten untereinander interpoliert. Hierdurch wird vermieden, dass die einzelnen Testdatenpunkte mit veränderten Versionen von sich selbst verglichen werden.

5.1.1. K-Nearest-Neighbor

Der k-NN Algorithmus wurde gewählt, da er ein einfaches, aber effektives Verfahren zur Klassifikation darstellt. Ein wichtiger Vorteil dieses Algorithmus ist, dass er kein Training benötigt, bevor er Daten zuordnen kann. Dies ist speziell für diesen Datensatz wichtig, da ein Training bei wenig Datenpunkten zu schlechten Klassifikationsergebnissen führen kann, da Overfitting auftreten kann [27].

Wie in den Grundlagen bereits erklärt, hängt die Genauigkeit des Algorithmus stark von der Wahl des Parameters k ab sowie von der Art der künstlichen Datengenerierung. In Tabelle 5.1 sind die erreichten Klassifikationsgenauigkeiten für verschiedene Werte von k , sowie für unterschiedlich viele interpolierte Punkte dargestellt:

Tabelle 5.1.: Ergebnisse der k-NN Klassifikation

Wert von k	Interpolierte Punkte	Genauigkeit (%)
2	0	25,03
3	0	22,45
5	0	14,5
2	2	25,90
3	2	23,59
5	2	16,99
2	5	26,19
3	5	19,9
5	5	18,6
2	10	24,59
5	10	18,8

Die Ergebnisse zeigen, dass die Klassifikation mithilfe des k-NN-Algorithmus grundsätzlich funktioniert, jedoch aufgrund der geringen Datenmenge keine zufriedenstellenden Ergebnisse erzielt werden. Besonders auffällig ist, dass unabhängig von der Anzahl interpolierter Datenpunkte das Ergebnis nie das Niveau von $k = 2$ bei einem höheren Wert von k erreicht. Dies lässt sich auf Kaffeesorten mit lediglich zwei Datenpunkten zurückführen: Sobald ein solcher Datenpunkt aus den Trainingsdaten entfernt wird, ist keine Interpolation mehr möglich, ohne auf den Testdatenpunkt zurückzugreifen. Dadurch werden andere Klassen stärker gewichtet, was die Klassifikation verzerrt.

Zudem zeigt sich, dass die Genauigkeit durch die Interpolation der Datenpunkte nicht verbessert werden konnte. Dies lässt sich damit erklären, dass unabhängig von der gewählten Interpolationsmethode nur wenig neue Datenpunkte entstehen, die näher an dem Testdatenpunkt sind als die Ursprünglichen, solange nicht explizit die Testdatenpunkte in den Interpolationsprozess einbezogen werden. Die Interpolation erhöht somit lediglich die Datendichte, trägt jedoch aufgrund der begrenzten Datenmenge kaum zur besseren Trennung der Klassen bei.

5.1.2. Naïve Bayes

Der Naïve-Bayes-Algorithmus wurde ausgewählt, da er, wie in den Grundlagen bereits beschrieben, sehr gut mit kleineren Datensätzen arbeiten kann und robust gegenüber Rauschen ist. Allerdings kann die Unabhängigkeitsannahme problematisch sein, wenn die Merkmale in der Realität voneinander abhängen, was zu suboptimalen Klassifikationsergebnissen führen kann.[18]

Wie in Tabelle 5.2 ersichtlich, zeigt sich bei diesem Algorithmus ohne künstliche Datengenerierung, dass Messpunkte desselben Kaffees nicht zuverlässig erkannt werden können. Da der Algorithmus Wahrscheinlichkeitsverteilungen für die einzelnen Merkmale

berechnet, hat er Schwierigkeiten, sehr ähnliche Messwerte voneinander zu unterscheiden. Auch die Interpolation der Trainingsdaten führt zu keiner signifikanten Verbesserung der Klassifikation.

Tabelle 5.2.: Ergebnisse der Naïve-Bayes-Klassifikation

Interpolierte Punkte	Genauigkeit (%)
0	9,96
1	10,67
2	11,4
5	12,99

Das grundlegende Problem dieses Algorithmus besteht darin, dass er auf Wahrscheinlichkeitsverteilungen innerhalb eines Zufallsraums basiert und daher tendenziell konvexe Räume bevorzugt. Aus den Ergebnissen wird ersichtlich, dass dieser Ansatz für den gegebenen Datensatz nicht geeignet ist, da die erzielte Genauigkeit lediglich geringfügig über der zufälligen Klassifikation von 16 Klassen liegt, welche bei 6,25 % zu erwarten wäre. Auch durch Interpolation der Datenpunkte kann nur eine minimale Verbesserung erzielt werden. Dies lässt sich auf die hohe Streuung der Messwerte zurückführen. Zudem spielt die in den Grundlagen beschriebene Unabhängigkeitsannahme eine entscheidende Rolle für den Erfolg des Algorithmus. Diese Annahme kann nicht erfüllt sein, da bei dem hier gewählten Ansatz ein Channel des Sensors mit einer Kurve approximiert wird, von welcher man dann die Kurvenparameter wiederum als Merkmale für das Training des Algorithmus nutzt. Da diese Kurvenparameter allerdings nur zusammen die korrekte Kurve ausgeben, ist die Unabhängigkeitsannahme hier nicht erfüllt.

5.2. Labeling der Kaffees für das Training

Die Zuordnung von Aromen aus den Kaffees (Tabelle 4.1) zu standardisierten Kategorien ist ein wesentlicher Schritt, um eine konsistente und systematische Klassifikation zu gewährleisten. Da die auf den Packungen angegebenen Aromen nicht immer mit den bestehenden Kategorien des Kaffee Aroma-Rads (Abbildung 2.1) übereinstimmen, muss eine strukturierte Label-Strategie entwickelt werden, um die Daten in eine einheitliche Form zu bringen.

5.2.1. Labeln des Kaffees in Überkategorien

Zunächst erfolgt die Zuordnung der auf den Kaffeepackungen genannten Aromen zu einer oder mehreren übergeordneten Kategorien, die typische Geschmacksprofile repräsentieren. So wird beispielsweise der Geschmack Nusskrokant zu den Kategorien nussig und braunem

Zucker zugeordnet. Dies ermöglicht eine flexible und präzise Abbildung von Aromen, die nicht direkt im Kaffee Aroma-Rad enthalten sind.

5.2.2. Mapping der Überkategorien auf Hauptaromen

Die Überkategorien werden anschließend auf die Hauptaromen wie floral, süß oder nussig/kakao zurückgeführt, um eine klare Einordnung innerhalb des Kaffee Aroma-Rads zu gewährleisten. Um das gesamte Rad darzustellen muss hierbei jedoch ein Aroma auch Merkmale in den benachbarten Hauptkategorien beinhalten. Außerdem wird berücksichtigt, dass die auf den Packungen zuerst genannten Aromen häufig dominanter sind. Die Aromen A erhalten daher bei der Berechnung ihrer Gewichtung einen Multiplikator w , der mit jedem folgenden Aroma, welches auf der Packung abgebildet war sank, bevor sie in die Gesamtaromenbewertung S einfließen. So ergibt sich der Zielvektor für das Training zu

$$S = \sum_{i=1}^n w_i A_i, \quad (5.1)$$

was dann als Resultat in einem Vektor endet, wie er in Abbildung 5.1 zu sehen ist. Hier wird das Aroma eines Kaffees durch die jeweiligen Intensitäten der Hauptaromen dargestellt. Mithilfe dieser Vektoren kann man nun die Ähnlichkeit der Kaffees analysieren. Diese Korrelationsmatrix aller Kaffeesorten ist in Abbildung 5.2 zu sehen. Aus dieser lassen sich zwei größere Cluster herauslesen, das eine umfasst die Proben 1, 5 bis 13 sowie Kaffee 15. Das andere Cluster umfasst die Kaffees 2 bis 4, 14 und 16. Diese Gruppen beschreiben schokoladige bzw. fruchtige Kaffees.




Abbildung 5.1.: berechnete Stärken der Hauptaromen für Kaffee 7




Abbildung 5.2.: Korrelationsmatrix der Kaffees

5.3. Mustererkennung in den Sensordaten

Für die Erkennung verborgener Muster und Strukturen in den Sensordaten wird Unsupervised Learning eingesetzt. Diese Methode erlaubt es, Gruppierungen innerhalb der Daten zu identifizieren, ohne dass zuvor gelabelte Zielvariablen erforderlich sind. Ziel ist es, eine sinnvolle Strukturierung der Kaffeesorten anhand ihrer Aromaprofile vorzunehmen.

In diesem Unterkapitel wird untersucht, welche Messungen aufgrund großer Messfehler keiner der anderen Kaffeesorten zugeordnet werden können. Zudem wird analysiert, ob sich Kaffees derselben Sorte mithilfe von Clustering-Algorithmen automatisch in einer gemeinsamen Gruppe wiederfinden. Weiterhin wird geprüft, welche der Proben besonders nahe beieinander liegen, wie dies beispielsweise in Tabelle 4.1 für Kaffee 5 und 6 der Fall ist. Diese beiden Kaffees weisen sehr ähnliche Hauptaromen auf (Schokolade & Pekannuss bzw. Schokoladencreme & Haselnuss). Da bei den Unsupervised Learning-Verfahren keine Unterteilung in Trainings- und Testdaten stattfindet, findet die künstliche Erzeugung neuer Daten hier für jeden Datenpunkt statt.

Für die Clusteranalyse werden die Algorithmen k-means und DBSCAN auf die Messdaten angewendet. Dabei wird die Anzahl der Cluster variiert, Ziel hiervon ist es unterschiedlich detaillierte Gruppierungen zu finden. Hierbei werden folgende Mengen an Clustern untersucht:

- **3 Cluster:** Identifikation der Hauptgeschmacksrichtungen wie schokoladig/nussig, fruchtig und eine Mischung aus beiden, wie man sie bereits in den Labels erkennen konnte.
- **9 Cluster:** Gruppierung in spezifischere Hauptaromagruppen, beispielsweise süß, fruchtig, floral usw.
- **16 Cluster:** Detaillierte Klassifikation der einzelnen Kaffeesorten.

Jede dieser Clusteranalysen wird sowohl mit als auch ohne Interpolation der Sensordaten durchgeführt. Dies ermöglicht es, den Einfluss der künstlich generierten Datenpunkte auf die Gruppierung der Kaffees zu bewerten.

5.3.1. Wieso diese Algorithmen?

5.3.1.1. DBSCAN

DBSCAN wurde gewählt, da er auch nicht konvexe Cluster erkennen kann, was ihn für die Analyse von komplexen Datenstrukturen attraktiv macht. Allerdings kann die Wahl der Parameter (ϵ und δ) die Ergebnisse stark beeinflussen und eine manuelle Anpassung erforderlich machen [20]. Um für den hier gewählten Ansatz das richtige δ zu finden wurde iterativ der Parameter erhöht, bis man die gewünschte Anzahl an Clustern gefunden hat und so wenig Punkte wie möglich als Rauschen erkannt werden. Ein großer Vorteil dieses

Algorithmus ist, dass er einzelne Punkte als Rauschen erkennen kann, wenn diese nicht direkt zu einem Cluster dazugehören bzw. der Abstand zu anderen Punkten zu groß ist. Hierdurch können mit erhöhter Wahrscheinlichkeit Cluster entstehen, die sinnvoll sind und beispielsweise Ähnlichkeiten in den Aromen zeigen.

5.3.1.2. K-Means

K-means wurde als zweiter Unsupervised Algorithmus ausgewählt, da er genauso wie auch DBSCAN ein Clustering Algorithmus ist allerdings, wie in den Grundlagen bereits beschrieben nur konvexe Räume zu einem Cluster zusammenfasst. Das größte Problem dieses Ansatzes ist, dass großes Rauschen in den ihm gegebenen Daten die Ergebnisqualität verschlechtert, da hier aufgrund der Gleichverteilung der Cluster Gruppierungen entstehen, die nur aus sehr wenig Punkten bestehen, wodurch die anderen Cluster zu viele Punkte erhalten und eine zu starke Verallgemeinerung entsteht [21].

5.3.2. Ergebnisse der Unsupervised Learning Verfahren

Die Ergebnisse in den Tabellen 5.3, 5.4 und A.1 zeigen, dass sich bestimmte Kaffeesorten hinsichtlich ihrer Sensordaten stärker ähneln als andere. Insbesondere Kaffees mit ausgeprägten Aromen wie Schokolade oder Frucht werden häufiger in gemeinsamen Gruppen zusammengefasst. Dies lässt sich besonders gut bei 9 Clustern sehen, da hier beispielsweise mit das erste Cluster des K-means Algorithmus nur schokoladige Proben beinhaltet, während Cluster 6 nur fruchtige enthält. Allerdings treten insbesondere bei der Clusteranzahl von 16 Fälle auf, in denen sich erwartete Gruppierungen nicht bestätigen. Dies zeigt sich sowohl in Clustern, die nur eine einzelne Kaffeesorte enthalten, jedoch nicht deren vollständige Messreihe, als auch in Gruppen, in denen ein Kaffee mit überwiegend fruchtigen Aromen einem Cluster mit schokoladigen Kaffees zugeordnet wird. Diese Unstimmigkeiten lassen sich durch die hohe Streuung der Daten erklären. Diese umfassen sowohl komplette Messreihen einzelner Kaffees als auch isolierte Messpunkte. Ein weiteres Problem war, dass DBSCAN ohne Interpolation der Klassen sowohl bei 9 Clustern, als auch bei 16 keine Gruppen finden konnte, was in den Ergebnissen durch "nicht erkennbar" gekennzeichnet wurde, da hier aufgrund der Ähnlichkeit der Daten nie die gesuchte Anzahl an Clustern gefunden werden konnte und somit alle Datenpunkte als Rauschen eingestuft wurden.

Aufgrund dieser Probleme erweist sich die Clusteranalyse mit drei Clustern als wenig aussagekräftig, da in einigen Fällen ein einzelner Kaffee ein ganzes Cluster dominiert. Dies führt dazu, dass die verbleibenden Cluster zu stark verallgemeinert werden. Ebenso erweist sich die Analyse mit 16 Clustern als problematisch, da einige Kaffees über mehrere Cluster verteilt sind, während andere in nur einem einzigen Cluster zusammengefasst werden. Die Clusteranalyse mit neun Clustern liefert hingegen bessere Ergebnisse. Zwar lassen sich hierdurch nicht alle Hauptaromen exakt differenzieren, jedoch ist eine klare

Trennung zwischen fruchtigen und schokoladigen Kaffees sowie einigen Mischformen erkennbar. Besonders bei der K-means Analyse mit oder ohne Interpolation wird diese Differenzierung deutlich, wie etwa in Cluster 9 des nicht interpolierten Algorithmus, das die Kaffees 13, 14, 15, 16 und 3 umfasst. Mit Ausnahme von Kaffee 15 enthält dieses Cluster ausschließlich fruchtige Proben.

Tabelle 5.3.: Ergebnisse der Analyse (3 Cluster)

Cluster	k-means	DBSCAN	k-means interpoliert	DBSCAN interpoliert
1	1, 9, 7	1	8	1
2	10, 11, 12, 13, 14, 15, 16, 2, 3, 4, 5, 6, 8	1, 4, 5, 7, 9	1, 5, 6, 7, 8	5
3	5, 6, 7, 8	jede andere Probe	jede andere Probe	jede andere Probe

Tabelle 5.4.: Ergebnisse der Analyse (9 Cluster)

Cluster	k-means	DBSCAN	k-means interpoliert	DBSCAN interpoliert
1	5, 6, 7	nicht erkennbar	2, 4, 6, 9, 10, 11, 12, 15	1
2	5, 8, 3	nicht erkennbar	5, 8	10
3	9, 3, 4	nicht erkennbar	1, 7	11, 12, 9, 6
4	1	nicht erkennbar	6, 7	13, 15
5	8	nicht erkennbar	9, 4, 3	14, 16
6	2, 4	nicht erkennbar	5, 7	2
7	10, 11, 12, 15, 2, 6, 8, 9	nicht erkennbar	1	3
8	7	nicht erkennbar	13, 14, 15, 16, 3, 8	5
9	13, 14, 15, 16, 3	nicht erkennbar	4	7

5.4. Vorhersage der Aromen

Zur Vorhersage der Hauptaromen eines Kaffees werden neuronale Netze eingesetzt, die die vorverarbeiteten Sensordaten als Eingabe erhalten und als Ausgabe eine Liste der vorhergesagten Hauptaromen generieren. Zur Validierung der Modellgüte wird der Datensatz in einen Trainings- und einen Testdatensatz unterteilt. Dabei werden einige Kaffees vollständig dem Testdatensatz zugeordnet, um sicherzustellen, dass das Modell nicht lediglich die Trainingsdaten auswendig lernt, sondern tatsächlich Muster in den Daten erkennt.

Um die Generalisierungsfähigkeit weiter zu verbessern, werden gezielt jene Kaffeesorten aus dem Trainingsdatensatz entfernt, die laut dem Labeling nur schwach durch andere Kaffees beschrieben werden. Hierfür wurde die Korrelation der Kaffees nach Abbildung 5.2 genutzt, indem für jede Probe die Summe der zur Korrelationen zu jeder anderen berechnet wurde. Daraus ergibt sich, dass die Kaffees 3, 14 und 16 am wenigsten durch die anderen dargestellt werden. Was eine zusätzliche Herausforderung für das Netz darstellt ist hierbei außerdem, dass alle 3 Proben hauptsächlich sauer und fruchtig waren und zu großen Teilen durch sich gegenseitig dargestellt wurden. Zudem werden zwei unterschiedliche Netzarchitekturen getestet: Ein Feedforward-Netz, das die approximierten Kurvenparameter als Eingabe erhält, sowie ein LSTM Netz, das auf den normalisierten Sensordaten basiert. Dieses wurde genutzt, um zu testen ob die zuvor genutzte Generierung der Trainingsdaten auf dem hier genutzten Datensatz sinnvoll ist, oder ob die reine Verarbeitung von Zeitreihendaten bessere Ergebnisse liefert.

5.4.1. Architektur der Netze

5.4.1.1. Feedforward Neural Network

Das Feedforward Neural Network besteht aus 3 vollständig verbundene Schichten mit Rectified Linear Unit (ReLU)-Aktivierungsfunktionen, die durch Dropout-Schichten zur ergänzt werden, um die Stabilität des Netzes zu erhöhen. ReLU wurde hierbei genutzt, da das geringste Aroma durch einen Wert von 0 dargestellt wird und somit alle Werte, die geringer sind zu 0 werden. Zuletzt gibt es noch die Ausgabeschicht, die 9 Werte hat, mit welchen wie zuvor beim Labeling die Intensitäten der Hauptaromen beschrieben werden.

5.4.1.2. LSTM Neural Network

Das LSTM Neural Network besteht ebenfalls aus 4 Schichten mit einer LSTM-Schicht mit 128 Neuronen, welche die zuvor verarbeiteten Zeitreihendaten beachten und somit den zeitlichen Verlauf der Messung analysieren. Danach folgen zwei weitere vollständig verbundene Schichten, die ebenfalls 128 Neuronen besitzen. Zuletzt kommt die Ausgabeschicht mit 9 Neuronen um für jedes Hauptaroma eine Intensität auszugeben. In diesem Netz wird jede Schicht mit einem Dropout behandelt, damit das Netz über das Training stabiler wird, außerdem wurde auch hier eine ReLU Aktivierungsfunktion genutzt.

Diese Architektur unterscheidet sich außerdem in den ihr gegebenen Eingabedaten. Diese sind die normierten Messungen ohne jegliche Approximation der Kurven. Dies liegt an der Funktionsweise des LSTM Netzes, welche vorherige Messpunkte noch weiter berücksichtigen kann und daher auf Zeitabhängige Eingangsdaten angewiesen ist.

5.4.2. Ergebnisse der Feedforward Architektur

Da es für die hier genutzten Sensoren keine vortrainierten Netze gibt, musste das Netz mehrfach mit zufälligen Startgewichten trainiert werden. Nach dem Training erreicht das Modell eine Validierungsgenauigkeit von 92%. Eine genaue Vorhersage der Aromen für die Kaffees, die es nicht trainiert hat, sind in der Abbildung 5.3 zu sehen. Anhand dieser Vorhersage kann man sehen, dass das Hauptaroma gut vorhergesagt werden konnte, jedoch ist es nicht möglich, alle Nebendaromen korrekt vorherzusagen, da die Kaffees mit ähnlichem Muster auch aus den Trainingsdaten entfernt werden. Dieses Theorie bestätigt auch Abbildung 5.4. Hier wurde Kaffee 3 wiederum in die Trainingsdaten aufgenommen und mit Kaffee 9 ersetzt, was eine deutlich bessere Vorhersage von den Proben 14 und 16 ermöglicht. Darüber hinaus wird der neu aufgenommene Kaffee, der nach dem Labeling sehr hohe Übereinstimmung mit anderen Kaffees hat, deutlich besser durch das Neuronale Netz vorhergesagt. Auch dies weist darauf hin, dass Kaffees die nach dem Labeling Ähnlichkeiten zeigen diese auch in den Messungen zeigen.




Abbildung 5.3.: Vorhersage der Kaffees 3, 14 & 16, wobei Blau der Zielvektor ist und Orange der Vorhergesagte




Abbildung 5.4.: Vorhersage der Kaffees 9, 14 & 16, wobei Blau der Zielvektor ist und Orange der Vorhergesagte

5.4.3. Ergebnisse der LSTM Architektur

Nach dem Training erreicht das Modell eine Validierungsgenauigkeit von 73 %. Eine detaillierte Darstellung der Vorhersagen für Kaffees, die nicht im Training berücksichtigt wurden, ist in der Abbildung 5.5 zu sehen.

Die Ergebnisse zeigen, dass das LSTM, ähnlich wie das klassische neuronale Netz, in der Lage ist, das Hauptaroma zuverlässig zu identifizieren und einige Nebendaromen korrekt zu erfassen. Unterschiede in der Validierungsgenauigkeit sind höchstwahrscheinlich auf Variationen in den Eingabedaten zurückzuführen. Da während der Vorverarbeitung nicht sämtliches Rauschen aus den Sensorkurven entfernt werden konnte, fließen weiterhin irrelevante Informationen in das Modell ein. Dies erschwert das Training des Netzes und beeinträchtigt die Qualität der Vorhersagen.

Zudem fällt auf, dass bei erneutem Training mit den Kaffees 9, 14 und 16 als Testdaten zwar für Kaffee 14 eine verbesserte Vorhersage erzielt wurde, jedoch die Aromen der Kaffees 9 und 16 nicht zuverlässig erkannt werden konnten. Auch dieses Verhalten lässt sich auf das verbleibende Rauschen in den Daten zurückführen, das die Trennung der Klassen erschwert.




Abbildung 5.5.: Vorhersage der Kaffees 3, 14 & 16 durch das LSTM Modell, wobei Blau der Zielvektor ist und Orange der Vorhergesagte




Abbildung 5.6.: Vorhersage der Kaffees 9, 14 & 16 durch das LSTM Modell, wobei Blau der Zielvektor ist und Orange der Vorhergesagte

6. Vergleich mit Smart Nanotubes

In diesem Kapitel werden die Datenaufnahme, sowie die Verarbeitung und die Analyse der Daten mit der Smart Nanotubes Technologie betrachtet. Hierfür wurden dieselben Algorithmen genutzt, wie für die QCM Technologie.

6.1. Aufnahme neuer Daten

Da der Sensor sehr empfindlich auf Gerüche und andere Veränderungen in der Umwelt reagiert, wurden die Daten in einem abgeschlossenen Raum aufgenommen. Hierfür wurde vor der Aufnahme der Daten 30 Minuten gelüftet, während der Sensor sich kalibriert. Danach wurden weitere 15 Minuten gewartet, damit sich die Luft im Raum gesetzt hat. Dieser Vorgang wurde vor jeder Messreihe unternommen, um stets dieselben Bedingungen zu schaffen.

Das Messverfahren erfolgte, indem der Sensor in einen Behälter mit den Kaffeebohnen platziert wurde. Anschließend wurde über einen Zeitraum von 30 Minuten kontinuierlich gemessen, um eine vollständige Sättigung des Sensors mit den flüchtigen organischen Verbindungen des Kaffees zu gewährleisten. Nach dieser Phase wurde der Behälter erneut verschlossen, und eine weitere 30-minütige Messung zur Erfassung der Desättigung durchgeführt.

Insgesamt wurden für sieben verschiedene Kaffeeproben jeweils zehn Messungen durchgeführt, die im weiteren Verlauf dieses Kapitels analysiert werden.

Die Kaffeeproben sind in Tabelle 6.1 zu sehen und haben nach dem Labeling eine Ähnlichkeit, die in Abbildung 6.1 zu sehen ist.

Tabelle 6.1.: Übersicht der Kaffeesorten

#	Kaffeesorte	Aromen
1	Kambarare estate	Erdbeere, Banane, Zwetschgenkompott
2	Halo Beriti	Earl Grey, Limette, Mandel
3	Kambarare estate	Erdbeere, Banane, Sauerkirschkonfitüre
4	Kambarare estate honey	Pfirsichblüte, Tomate, Johannisbeere
5	Izuba Ryamukona	Rhabarberkompott, Rooibos, Holunder
6	Caturra Lactic	Karamellpopcorn, Birne, Mandel
7	Suke Quto	Himbeere, Grenadine, Rose




Abbildung 6.1.: Ähnlichkeit der Kaffees der Messreihe für smart Nanotubes

6.2. Datenvorbereitung

Da der Sensor keine ausgeprägten Messfehler aufwies und lediglich einige Sensoren nur minimale Signaländerungen zeigten, waren nur geringe Korrekturen erforderlich. Alle Sensoren konnten somit uneingeschränkt genutzt werden.

Die Normalisierung erfolgte analog zur bisherigen Technologie im Wertebereich zwischen 0 und 5. Allerdings war in diesem Fall keine Spiegelung der Kurven erforderlich, da der Ausschlag des Sensors gemäß Formel 2.2 bereits in positiver Richtung erfolgte.

Auch die Approximation der Sättigungsgleichung wurde wie zuvor durchgeführt, jedoch ausschließlich mithilfe von Formel 4.2.

6.3. Vorhersage der Klassifikation

Um eine vergleichbare Aussage über die Klassifikationsgenauigkeit zu treffen wird dieser Datensatz genauso analysiert, wie der bisherige auch. Jedoch da hier nur 7 Proben sind anstelle von 16, müssen die Ergebnisse anders gewichtet werden.

6.3.1. kNN

Die Ergebnisse, in Tabelle 6.2 zeigen, dass generell die Klassifikation mit den Daten aus dem Smart Nanotubes Sensor besser funktioniert, als mit dem QCM Sensor. Besonders auffällig ist, dass, anders als mit dem bisherigen Datensatz mit den Ergebnissen 5.1, die Genauigkeit der Klassifikation hier durch die Interpolation gesteigert werden konnte. Dies lässt sich auf die erhöhte Datenmenge der Datenpunkte innerhalb einer Klasse zurückführen, da hier die Wahrscheinlichkeit höher ist, dass ein Datenpunkt in der Menge zwischen 2 anderen liegt. Außerdem ist das Problem mit den Klassen bestehend aus 2 Datenpunkten nun nicht mehr gegeben, was zu einem eindeutigeren Ergebniss führt.

Tabelle 6.2.: Ergebnisse der k-NN Klassifikation

Wert von k	Interpolierte Punkte	Genauigkeit (%)
2	0	31,14%
3	0	29,68%
5	0	29,4%
2	2	36,85%
3	2	37,42%
5	2	36,71%
2	5	40,85%
3	5	38,42%
5	5	39,71%
2	10	38,42%
5	10	37,57%

6.3.2. Naïve Bayes

Wie in Tabelle 6.3 ersichtlich, erzielt die Klassifikation mit dem Naïve-Bayes-Algorithmus in diesem Fall deutlich bessere Ergebnisse als mit dem ersten Datensatz (siehe Tabelle 5.2). Dies lässt sich durch die Funktionsweise des Algorithmus erklären, der Datenpunkte basierend auf der Wahrscheinlichkeit zuordnet, mit der ein Merkmal einer bestimmten Klasse angehört. Da in diesem Datensatz deutlich mehr Punkte pro Klasse als Referenz dienen, ist die Wahrscheinlichkeit höher, dass ein Testdatenpunkt innerhalb des Verteilungsraums der vorhandenen Datenpunkte liegt, was die Klassifikationsgenauigkeit verbessert.

Tabelle 6.3.: Ergebnisse der Naïve-Bayes-Klassifikation

Interpolierte Punkte	Genauigkeit (%)
0	41,76
1	43,57
2	39,28
5	42,28

6.4. Unsupervised Learning

Die Ergebnisse der Clusteranalysen mit k-Means und DBSCAN belegen, dass die Sensordaten eine erhebliche Streuung aufweisen, was zu einer inkonsistenten Clusterbildung führt. So fasst k-Means bei einer niedrigen Clusteranzahl viele Kaffeesorten in einem einzigen Cluster zusammen (vgl. Tabelle 5.3), während erst bei einer höheren Clusteranzahl vereinzelte, jedoch unscharfe Gruppierungen erkennbar werden (siehe Tabellen 6.5 und 6.6). Ähnliche Probleme zeigen sich auch bei der Anwendung von DBSCAN, wo zum Teil unerklärliche Cluster entstehen, die sich nicht dem tatsächlichen Unterschieden der Kaffees zuordnen lassen.

Besonders auffällig ist die fehlende Übereinstimmung zwischen eigentlich identischen Kaffeesorten, wie etwa Kaffee 1 und Kaffee 3, die trotz ähnlicher Probenlage in unterschiedlichen Clustern erscheinen. Dies könnte auf externe Einflüsse, wie variierende Messbedingungen, nicht genügend Messungen oder Unterschiede in den Röstchargen zurückzuführen sein. Auch die Interpolation der Daten, welche lediglich zu einer höheren Datendichte führte, brachte keine signifikante Verbesserung der Clustertrennung.

Zusammenfassend lässt sich feststellen, dass die vorhandenen Sensordaten qualitativ nicht ausreichend sind, um eine zuverlässige und reproduzierbare Klassifikation der Kaffees zu gewährleisten. Die hohe Variabilität und die unklare Abgrenzung der Cluster, wie in den Tabellen 6.4 bis 6.6 dokumentiert, unterstreichen diesen Befund.

Tabelle 6.4.: Ergebnisse der Analyse (3 Cluster)

Cluster	k-means	DBSCAN	k-means interpolated	DBSCAN interpolated
1	5	1, 2, 3, 4, 5, 6, 7	1, 2, 3, 4, 5, 7	1, 2, 3, 4, 5, 6, 7
2	1, 2, 3, 4, 5, 6, 7	3, 4, 6, 7	1, 2, 3, 4, 5, 6, 7	2
3	1, 2, 3, 4, 6, 7	4	3, 4, 6, 7	5

Tabelle 6.5.: Ergebnisse der Analyse (5 Cluster)

Cluster	k-means	DBSCAN	k-means interpolated	DBSCAN interpolated
1	1, 2, 4, 5, 6, 6	1	2, 5	1, 2, 3, 4, 5, 6, 7
2	1, 2, 3, 5, 6, 7	3, 4, 5, 6, 7	2, 3, 5, 6, 7	2
3	1, 2, 3, 4, 5, 7	4	1, 2, 4	2
4	2	4	1, 2, 3, 4, 5, 7	4, 6, 7
5	3, 4, 6, 7	6	3, 4, 6, 7	5

Tabelle 6.6.: Ergebnisse der Analyse (7 Cluster)

Cluster	k-means	DBSCAN	k-means interpolated	DBSCAN interpolated
1	1, 2, 4	1	2, 3, 5, 6, 7	1, 2, 3, 4, 5, 6, 7
2	1, 2, 3, 4, 5, 6, 7	3, 5, 6	1, 2, 3, 4, 5, 7	2
3	4	3, 4, 5, 7	3, 4, 6, 7	3, 4, 6, 7
4	2, 3, 5	3, 5	3, 4, 5, 6, 7	4, 7
5	1	4	1, 2, 3, 4, 5, 7	5
6	1, 2, 3, 4, 5, 7	4	1	6
7	3, 6, 7	5, 7	2	6

6.5. Neuronale Netze

Für das Messen der Genauigkeit der Aromadetektion wurden hier auch wieder dieselben Netze, wie zuvor genutzt. Ebenfalls wird hier wieder der am schlechtesten durch die anderen Kaffees dargestellte Kaffee genutzt um die Netze zu testen, die Ähnlichkeit der einzelnen Kaffees ist in Abbildung 6.1 dargestellt. Hieraus ergibt sich, dass Kaffee 6 die geringste Übereinstimmung mit allen anderen Kaffees hat. Um weitere Proben zu beachten, wurde außerdem Kaffee 4 untersucht.

Die Analyse des neuen Datensatzes führte zur Bestimmung der Aromen anhand der Abbildungen 6.2 und 6.3. Dabei zeigte sich, dass das Aroma von Kaffee 4 gut erkannt wurde, während die Klassifikation von Kaffee 6 deutlich unzuverlässiger war. Dieses Verhalten ließ sich sowohl beim Feedforward-Netz als auch beim LSTM beobachten.

Zudem fällt auf, dass die Vorhersagen beider Proben eine hohe Ähnlichkeit aufweisen. Dies deutet darauf hin, dass die Modelle mit zu ähnlichen Proben trainiert wurden, wodurch die Differenzierung erschwert wird. Diese Annahme wird durch die Labelverteilung in Abbildung 6.1 gestützt, in der alle Proben – mit Ausnahme von Kaffee 6 – eine Übereinstimmung von über 80 % aufweisen.



Abbildung 6.2.: Vorhersage der Kaffees 4 & 6 mit dem Feedforward Netz




Abbildung 6.3.: Vorhersage der Kaffees 4 & 6 mit dem LSTM Netz

7. Ausblick

Das Ziel dieser Arbeit war es, die Klassifikation von Kaffeearomen mithilfe elektronischer Nasen und maschineller Lernverfahren zu untersuchen. Hierfür wurden zwei unterschiedliche Sensortechnologien – ein QCM-Sensor und der Smell Inspector von Smart Nanotubes – hinsichtlich ihrer Eignung zur Erfassung von Kaffeearomen evaluiert. Dabei wurden verschiedene Methoden des überwachten und unüberwachten Lernens eingesetzt, um die Sensordaten zu analysieren und die Klassifikationsgenauigkeit zu bewerten.

Die Ergebnisse zeigen, dass beide Sensortechnologien sowohl Vor- als auch Nachteile aufweisen. Während der QCM-Sensor durch eine hohe Messgenauigkeit überzeugte, war die Genauigkeit der Klassifikation durch wenig Messungen pro Klasse begrenzt. Die Smart Nanotubes bestätigen durch mehr Messungen diese These, da sie eine höhere Genauigkeit bei den Klassifikationsalgorithmen erzielten, auch wenn die Messungen nicht in einem Labor aufgenommen wurde und somit ungenauer waren. Besonders bei unüberwachten Lernverfahren zeigte sich, dass der QCM-Sensor stabilere Clusterstrukturen lieferte, da hier einige Strukturen, die in den Labels gefunden wurden auch hier erkannt werden konnten. Die Smart Nanotubes dahingegen hatte nur verallgemeinerte Gruppen und Ausreißer erkennen können, was sich allerdings auch durch die Ähnlichkeit der hier aufgenommenen Proben erklären lässt.

Darauf aufbauend wurde neben der reinen Erkennung der Kaffeesorte auch untersucht, ob mithilfe neuronaler Netze eine Analyse der Kaffeearomen anhand der vorliegenden Datensätze möglich ist. Zu diesem Zweck wurde eine Labeling-Strategie entwickelt, die auf Basis der auf der Kaffeepackung angegebenen Aromen einen Zielvektor für das Training der neuronalen Netze erzeugt. Zudem wurden sowohl Feedforward-Netze als auch LSTM-Netze für die korrekte Aromaermittlung getestet.

Die Ergebnisse dieser Analyse zeigen, dass Kaffees, die nach dem Zielvektor ähnlich sein sollten, dieses Verhalten auch in den Sensordaten widerspiegeln. Die neuronalen Netze waren in der Lage, Kaffees, von denen sie bereits eine ähnliche Sorte kennengelernt hatten, korrekt zu erkennen und das passende Aroma zuzuordnen. Dies gelang jedoch nur, wenn das Netz zuvor mit ausreichend ähnlichen Kaffees trainiert wurde. Beispielsweise konnte eine Testmessung mit dem Smart-Nanotubes-Sensor nicht korrekt zugeordnet werden, wie in 6.2 dargestellt.

Auf Grundlage dieser Erkenntnisse wird für zukünftige Untersuchungen empfohlen, die Datensätze durch zusätzliche Proben zu erweitern, um ein effektiveres Training der Algorithmen zu ermöglichen. Falls weiterhin mit dem Smart-Nanotubes-Sensor gearbeitet

wird, sollte zudem ein optimierter Versuchsaufbau entwickelt werden, um externe Umwelteinflüsse zu minimieren. Darüber hinaus wäre es sinnvoll, die sensorischen Erfahrungen menschlicher Tester beim Cupping stärker in die Erzeugung der Trainingsdaten einzubeziehen. Beispielsweise könnten Messungen von Bohnen, Kaffeepulver sowie gekochtem und wieder abgekühltem Kaffee kombiniert werden, um eine möglichst umfassende Erfassung der Aromen zu gewährleisten.

A. Anhang

Tabelle A.1.: Ergebnisse der Analyse (16 Cluster)

Cluster	K-Means	DBSCAN	K-Means interpolated	DBSCAN interpolated
1	6, 7	nicht erkennbar	6, 8	1
2	13, 14, 15, 16, 3, 8	nicht erkennbar	1	1
3	9, 4	nicht erkennbar	9, 2, 15, 11	10
4	9, 6, 4, 2, 15, 10, 11, 12	nicht erkennbar	6, 7, 9	11, 12
5	1	nicht erkennbar	9, 6, 4, 12	13, 15
6	1	nicht erkennbar	3, 4	14
7	8	nicht erkennbar	1	2
8	7	nicht erkennbar	5	2
9	5	nicht erkennbar	10, 11, 2	3
10	4	nicht erkennbar	14, 13	5
11	1	nicht erkennbar	8	7
12	5	nicht erkennbar	9, 4, 3	9
13	3	nicht erkennbar	5, 8	6
14	8	nicht erkennbar	8	7
15	10	nicht erkennbar	3, 15, 16, 13	9
16	5	nicht erkennbar	7	9

Abkürzungen

CNN	Convolutional Neural Network
DBSCAN	Density-Based Spatial Clustering of Applications with Noise
DNN	Deep Neural Network
E-Nose	electronic nose
KI	künstliche Intelligenz
k-NN	k-Nearest-Neighbor
LSTM	Long short-term memory
MOF	Metal-Organic Framework
MSE	Mean Square Error
ORN	olfaktorische Rezeptorneuronen
PCA	Principal Component Analysis
QCM	Quartz-Crystal-Microbalance
ReLU	Rectified Linear Unit
RNN	Rekurrente neuronale Netze
SCA	Specialty Coffee Association
SURMOFs	surface-mounted Metal-Organic Frameworks
SVMs	Support Vector Machines
VOCs	volatile organische Verbindungen

Symbole

Symbol	Unit	Description
Δf	Hz	Frequenzdifferenz
k		Anzahl der nächsten Nachbarn
ϵ		Anzahl weiterer Punkte in einem Cluster
δ		zu untersuchender Radius des DBSCAN Algorithmus
x_i		Die Messung mit dem Index i
ρ_q	kg/m ³	Dichte
μ_q	N/m ²	Schermodul
f_0	Hz	Resonanzfrequenz
A	m ²	Oberfläche
Δm	kg	Masseänderung
R_g	Ω	Widerstand unter VOC Exposition
R_0	Ω	Basiswiderstand

Literatur

- [1] Wenny B. Sunarharum, David J. Williams und Heather E. Smyth. „Complexity of coffee flavor: A compositional and sensory perspective“. In: *Food Research International* 62 (2014), S. 315–325. ISSN: 0963-9969. DOI: <https://doi.org/10.1016/j.foodres.2014.02.030>. URL: <https://www.sciencedirect.com/science/article/pii/S0963996914001409>.
- [2] Tchibo Kaffeeakademie. *Aromastoffe*. Feb. 2025. URL: <https://www.tchibo.de/kaffeeakademie/wiki/aromastoffe>.
- [3] tchibo wiki. <https://www.tchibo.de/kaffeeakademie/wiki/aromastoffe>. Accessed on 04/02/2025.
- [4] Specialty Coffee Association. *How to Use the Flavor Wheel in Eight Steps*. Feb. 2025. URL: <https://sca.coffee/sca-news/how-to-use-the-flavor-wheel-in-eight-steps>.
- [5] Specialty Coffee Association Germany. *Protokolle und Best Practices*. Feb. 2025. URL: <https://scagermany.coffee/protokolle-und-best-practices/>.
- [6] Coffee Circle. *Das Kaffeearoma Rad*. Feb. 2025. URL: <https://cdn.coffeecircle.com/7a3c2e0d-de5b-49fb-a832-30de45698090/-/inline/yes/>.
- [7] A. Rinaldi. „The scent of life. The exquisite complexity of the sense of smell in animals and humans“. In: *EMBO Reports* 8.7 (2007), S. 629–633. DOI: 10.1038/sj.embor.7401029.
- [8] Dr. med. Cornelia Hummel. *Jugendinfo – Interdisziplinäres Zentrum für Riechen und Schmecken*. Fetscherstrasse 74, Dresden, Feb. 2025. URL: <https://www.uniklinikum-dresden.de/de/das-klinikum/kliniken-polikliniken-institute/hno/forschung/interdisziplinaeres-zentrum-fuer-riechen-und-schmecken/downloads/downloads/jugendinfo.pdf>.
- [9] AOK – Die Gesundheitskasse. *Geruchssinn: Wie wir riechen*. Feb. 2025. URL: <https://www.aok.de/pk/magazin/koerper-psyche/gehirn-nerven/geruchssinn-wie-wir-riechen/>.
- [10] A. Sharma u. a. „Sense of Smell: Structural, Functional, Mechanistic Advancements and Challenges in Human Olfactory Research“. In: *Current neuropharmacology* (2019). DOI: 10.2174/1570159X17666181206095626.

- [11] Julian W. Gardner und Philip N. Bartlett. „A brief history of electronic noses“. In: *Sensors and Actuators B: Chemical* 18.1 (1994), S. 210–211. ISSN: 0925-4005. DOI: [https://doi.org/10.1016/0925-4005\(94\)87085-3](https://doi.org/10.1016/0925-4005(94)87085-3). URL: <https://www.sciencedirect.com/science/article/pii/0925400594870853>.
- [12] Jay Rana und Sonal Desai. „Recent advances in e-nose for potential applications in Covid-19 infection“. In: *Talanta Open* 10 (2024), S. 100363. ISSN: 2666-8319. DOI: <https://doi.org/10.1016/j.talo.2024.100363>. URL: <https://www.sciencedirect.com/science/article/pii/S2666831924000778>.
- [13] Peng Qin u. a. „A MOF-based electronic nose for carbon dioxide sensing with enhanced affinity and selectivity by ionic-liquid embedment“. In: *Journal of Materials Chemistry A* 10 (Jan. 2022). DOI: 10.1039/D2TA06324G.
- [14] Luis Antonio Panes-Ruiz u. a. „Toward Highly Sensitive and Energy Efficient Ammonia Gas Detection with Modified Single-Walled Carbon Nanotubes at Room Temperature“. In: *ACS Sensors* 3.1 (2018). PMID: 29186954, S. 79–86. DOI: 10.1021/acssensors.7b00358. eprint: <https://doi.org/10.1021/acssensors.7b00358>. URL: <https://doi.org/10.1021/acssensors.7b00358>.
- [15] Ruud Peters u. a. „Evaluation of a Commercial Electronic Nose Based on Carbon Nanotube Chemiresistors“. In: *Sensors* 23.11 (2023). ISSN: 1424-8220. DOI: 10.3390/s23115302. URL: <https://www.mdpi.com/1424-8220/23/11/5302>.
- [16] Jafar Alzubi, Anand Nayyar und Akshi Kumar. „Machine Learning from Theory to Algorithms: An Overview“. In: *Journal of Physics: Conference Series* 1142.1 (Nov. 2018), S. 012012. DOI: 10.1088/1742-6596/1142/1/012012. URL: <https://dx.doi.org/10.1088/1742-6596/1142/1/012012>.
- [17] Zhang Z. „Introduction to machine learning: k-nearest neighbors“. In: *Ann Transl Med.* (2016). DOI: 10.21037/atm.2016.03.37.
- [18] scikit-learn. version 1.9. URL: https://scikit-learn.org/1.5/modules/naive_bayes.html.
- [19] Zheng Xing und Weibing Zhao. „Block-Diagonal Guided DBSCAN Clustering“. In: *IEEE Transactions on Knowledge and Data Engineering* 36.11 (2024), S. 5709–5722. DOI: 10.1109/TKDE.2024.3401075.
- [20] scikit-learn. version 1.9. URL: <https://scikit-learn.org/1.5/modules/generated/sklearn.cluster.DBSCAN.html>.
- [21] scikit-learn. version 1.9. URL: <https://scikit-learn.org/1.5/modules/generated/sklearn.cluster.KMeans.html>.
- [22] Inga Döbel u. a. *Maschinelles Lernen: Eine Analyse zu Kompetenzen, Forschung und Anwendung*. In Kooperation mit Forschungszentrum Maschinelles Lernen im Fraunhofer-Cluster of Excellence Cognitive Internet Technologies und Fraunhofer-Allianz Big Data Künstliche Intelligenz. Gefördert durch das Bundesministerium für Bildung und Forschung (BMBF). 2018. URL: [50](https://www.bigdata-

</div>
<div data-bbox=)

- ai.fraunhofer.de/content/dam/bigdata/de/documents/Publicationen/Fraunhofer_Studie_ML_201809.pdf.
- [23] Stefan Selle. *Künstliche Neuronale Netzwerke und Deep Learning*. Professor für Wirtschaftsinformatik, Fakultät für Wirtschaftswissenschaften. Zugriff am 5. Februar 2025. Saarbrücken, Mai 2018. URL: https://www.htwsaar.de/wiwi/fakultaet-und-personen/profile/selle-stefan/dateien/kuenstliche-neuronale-netzwerke/selle2018e_kuenstliche_neuronale_netzwerke.pdf.
- [24] GeeksforGeeks. *Artificial Neural Networks and Its Applications*. Zugriff am 24. März 2025. URL: <https://www.geeksforgeeks.org/artificial-neural-networks-and-its-applications/>.
- [25] Somia Bibi u. a. „An LSTM-Based Outlier Detection Approach for IoT Sensor Data in Hierarchical Edge Computing“. In: *2023 International Conference on Software, Telecommunications and Computer Networks (SoftCOM)*. Split, Croatia, Sep. 2023, S. 1–6. DOI: 10.23919/SoftCOM58365.2023.10271607.
- [26] A. Rudolph, J. Krois und K. Hartmann. *Smoothing by filtering (moving average)*. (Accessed on 30/01/2025). 2023. URL: <https://www.geo.fu-berlin.de/en/v/soga-py/Advanced-statistics/time-series-analysis/Smoothing/Smoothing-by-filtering/index.html>.
- [27] scikit-learn. version 1.7. URL: <https://scikit-learn.org/stable/modules/generated/sklearn.neighbors.KNeighborsClassifier.html>.

Tabellenverzeichnis

4.1. Übersicht der Kaffeesorten	18
5.1. Ergebnisse der k-NN Klassifikation	27
5.2. Ergebnisse der Naïve-Bayes-Klassifikation	28
5.3. Ergebnisse der Analyse (3 Cluster)	33
5.4. Ergebnisse der Analyse (9 Cluster)	33
6.1. Übersicht der Kaffeesorten	38
6.2. Ergebnisse der k-NN Klassifikation	40
6.3. Ergebnisse der Naïve-Bayes-Klassifikation	41
6.4. Ergebnisse der Analyse (3 Cluster)	41
6.5. Ergebnisse der Analyse (5 Cluster)	42
6.6. Ergebnisse der Analyse (7 Cluster)	42
A.1. Ergebnisse der Analyse (16 Cluster)	46

Abbildungsverzeichnis

2.1. Das Kaffeearoma Rad der SCA [6]	4
2.2. The human olfactory system [7]. Die Aufnahme und Verarbeitung von Gerüchen in der menschlichen Nase.	6
2.3. Aufbau eines künstlichen neuronalen Netzes [24]	12
3.1. Gegenüberstellung der menschlichen und maschinellen Erkennung von Gerüchen	16
4.1. Auszug aus den Rohdaten mit allen Sensoren	18
4.2. Auszug aus den Rohdaten mit ausgewählten Sensoren.	19
4.3. Nicht korrigierte Messung eines Channels des QCM Sensors.	20
4.4. Korrigierte Messung eines Channels des QCM Sensors.	21
4.5. Gefilterte und normierte Sensorkurve	22
4.6. Approximierte Kurve nach Formel 4.2	23
4.7. Approximierte Kurve nach Formel 4.3	24
4.8. Interpolierte Kurven mit 5 Interpolationen	25
5.1. berechnete Stärken der Hauptaromen für Kaffee 7	30
5.2. Korrelationsmatrix der Kaffees	30
5.3. Vorhersage der Kaffees 3, 14 & 16, wobei Blau der Zielvektor ist und Orange der Vorhergesagte	35
5.4. Vorhersage der Kaffees 9, 14 & 16, wobei Blau der Zielvektor ist und Orange der Vorhergesagte	35
5.5. Vorhersage der Kaffees 3, 14 & 16 durch das LSTM Modell, wobei Blau der Zielvektor ist und Orange der Vorhergesagte	36
5.6. Vorhersage der Kaffees 9, 14 & 16 durch das LSTM Modell, wobei Blau der Zielvektor ist und Orange der Vorhergesagte	37
6.1. Ähnlichkeit der Kaffees der Messreihe für smart Nanotubes	39
6.2. Vorhersage der Kaffees 4 & 6 mit dem Feedforward Netz	43
6.3. Vorhersage der Kaffees 4 & 6 mit dem LSTM Netz	43