

Exploration unterschiedlicher KI- Modelle zur objektiven Kaffearomabestimmung

Tim Quenzer

Institut für Technik der Informationsverarbeitung (ITIV)

25.03.2025

Bestimmung von Kaffeearomen

Vorgang „Cupping“

durchgeführt durch Experten

→ Extra Ausbildung nötig

Einteilung anhand des Kaffeearomara



Bestimmung von Kaffeearomen

Vorgang „Cupping“

durchgeführt durch Experten

→ Extra Ausbildung nötig

Einteilung anhand des Kaffeearomara

Problem:

- nicht objektiv
- Zeitaufwendig
- teuer



Grundlagen Kaffeearomen – Entstehung & Bedeutung

- über 800 Aromastoffe
 - Aroma entsteht durch Röstung, Anbaugebiet & Bohnensorte
- Analyse der einzelnen Moleküle nicht möglich


Grundlagen Kaffeearomen – Entstehung & Bedeutung

- über 800 Aromastoffe
 - Aroma entsteht durch Röstung, Anbaugebiet & Bohnensorte
- Analyse der einzelnen Moleküle nicht möglich

Lösung:

E-Noses & KI zur objektiven Aromabestimmung

- Rezeptoren in der Nase
- Elektrische Signale → Riechkolben
- Synapsen erkennen Geruch




E-Nose – Funktionsweise & Prinzip

- **Elektronische Nase (E-Nose)** nutzt Sensorenarrays
- Entstehung von Fingerabdrücken für jede Messung
- Hier genutzte Sensoren:
 - **QCM-Sensoren (Quartz Crystal Microbalance)**
(Sensor am Campus Nord)
 - **Smart Nanotubes-Sensoren**
(Handheld Gerät)

Grundlagen QCM-Sensor


- 32 unterschiedliche Sensoren
- Sensoren werden zum Schwingen angeregt
- Flüchtige Moleküle werden in „Schwamm“ aufgefangen
- Gewichtsänderung → Frequenz sinkt
- Frequenzänderung wird aufgezeichnet



Quelle: Salih Okur (DOI:
[10.1039/D2TA06324G](https://doi.org/10.1039/D2TA06324G))


Grundlagen Smart Nanotubes Sensor

- 64 unterschiedliche Sensoren
- Carbon Nanotubes dienen als Schwamm
- Elektrischer Widerstand wird aufgenommen
- Adsorption → Erhöhung des el. Widerstands
- Widerstandsänderung wird aufgezeichnet



Quelle: Evaluation of a Commercial Electronic Nose Based on Carbon Nanotube Chemiresistors (DOI: 10.3390/s23115302)

- Sensoren in der E-nose
- Datenvorbereitung
- Künstliche Neuronale Netze



Zielsetzung der Arbeit

- **Klassifikationsmodell für Kaffeearomen**

- **Kernfragen:**


Unterscheiden sich Kaffeesorten basierend auf Sensordaten?

Kann man anhand der Messungen Geschmackrichtungen unterscheiden?

Wie gut kann man die Aromen eines Kaffees approximieren?

Die genutzten Datensätze

Allgemein: Messung besteht aus Sättigungsphase mit Kaffee und Entsättigungsphase



QCM-Sensor:



- 16 Kaffeesorten
- Gemessen als gemahlene Bohne
- 41 Messungen
- Kaffee abgelaufen → keine neue Messung möglich

Smart Nanotubes Sensor:

- 7 Kaffeesorten
- Gemessen als ganze Bohne
- 69 Messungen


Fehleranalyse & Filterung der Daten:

- Sensorselektion
- Ausreißer entfernen
- Glättung der Kurven





Normalisierung für Vergleichbarkeit:

- Offset-Korrektur
- Min-Max-Skalierung
- Spiegelung der Sensordaten



Normierte Sensorkurve

Generierung von Trainingsdaten



$$f(x) = p_0 \cdot e^{(p_1 x + p_2)} + p_3$$

$$f(x) = e^{(p_0 x^3 + p_1 x^2 + p_2 x + p_3)} + p_4$$

Generierung von Trainingsdaten

2 x 4 Faktoren sowie min & max


→ 10 Faktoren pro Channel

32 Channel

→ ca. 320 Merkmale pro Messung

Insgesamt:

41 Vektoren mit 320 Dimensionen



$$f(x) = p_0 \cdot e^{(p_1 x + p_2)} + p_3$$


Data Augmentation

Künstliche Generierung neuer Datenpunkte durch Interpolation

- Ansatz: lineare Interpolation der einzelnen Merkmale
- Zusätzliche Rauschfunktion

Probleme:

- Reine Verstärkung existierender Strukturen
- Erzeugung von konvexen Merkmalsräumen



Methodik

Unterscheiden sich Kaffeesorten basierend auf Sensordaten?



→ Klassifikation(k-NN, Naïve Bayes)

Kann man anhand der Messungen Geschmackrichtungen unterscheiden?

→ Clustering(DBSCAN, k-Means)

Wie gut kann man die Aromen eines Kaffees approximieren?

→ Neuronale Netze (Feedforward, LSTM)



QCM Datensatz nach PCA

Smart Nanotubes Datensatz

Ergebnisse

k-Nearest-Neighbor

QCM Sensor

k	Interpolierte Punkte	Genauigkeit [%]
2	0	25.03
5	0	14.5
2	5	26.2
5	5	18.6
2	10	24.59
5	10	18.8

Smart Nanotubes Sensor

k	Interpolierte Punkte	Genauigkeit [%]
2	0	31.14
5	0	29.4
2	5	40.85
5	5	39.71
2	10	38.42
5	10	37.57

QCM-Sensor

Interpolierte Punkte	Genauigkeit [%]
0	9.96
1	10.67
2	11.4
5	12.99

Smart Nanotubes Sensor

Interpolierte Punkte	Genauigkeit [%]
0	41.76
1	43.57
2	39.28
5	42.28


Problem: Unabhängigkeitsannahme

→ Ansatz nicht sinnvoll

Labeling der Kaffees



Übersetzung der Aromen auf den Packungen zu Zahlenwerten der Hauptaromen.

Bsp: Schokolade, Pekannuss, Apfelkuchen



Ergebnisse

Ähnlichkeit nach Labeling





QCM-Datensatz

Smart Nanotubes-Datensatz

Ergebnisse

Label vs Messung






Korrelationsmatrix Label

Korrelationsmatrix Messung




Cluster	K-means	DBSCAN
1	5, 6, 7	1
2	5, 8, 3	10
3	9, 3, 4	11,12,9,6
4	1	13,15
5	8	14,16
6	2,4	2
7	10,11,12,15,2,6, 8,9	3
8	7	5
9	13, 14, 15, 16, 3	7

Cluster	K-means	DBSCAN
1	2,5	1,2,3,4,5,6, 7
2	2,3,5,6,7	2
3	1,2,4	2
4	1,2,3,4,5,7	4,6,7
5	3,4,6,7	5




Ergebnisse der Cluster des QCM-Sensors (links) &
des Smart Nanotubes Sensors (rechts)






Vorhersage der
Kaffees 3,14 & 16





Vorhersage der
Kaffees 9,14 & 16





Vorhersage der
Kaffees 3,14 & 16



Vorhersage der
Kaffees 9,14 & 16



Vorhersage der Kaffees
4 & 6 Feedforward



Vorhersage der Kaffees
4 & 6 LSTM

Ausblick

Verbesserung der Vorhersage:

- Genauigkeit der Sensoren verbessern
- Versuchsaufbau verbessern
- Mehr Messungen benutzen
- Ausweitung auf andere Bereiche (Wein, Whiskey)



Machine Learning für die Klassifikation von Kaffeearomen

- **Überwachtes Lernen** (k-NN, Naïve Bayes) → Klassifikation bekannter Kaffeesorten.
- **Unüberwachtes Lernen** (DBSCAN, k-Means) → Mustererkennung in Sensordaten.
- **Neuronale Netze (LSTM, Feedforward)** zur verbesserten Aroma-Vorhersage.

Genutzte Kaffees

#	Kaffeesorte	Aromen
1	Karma&Co	Dunkle Schokoladenmousse, Nusskrokant
2	La Cristalina	Orangenschale, Aprikose, Pflaumenwein
3	Candy	Apfelwein, rote Früchte
4	Las Alegrias	Aprikose, gelber Pfirsich, süß wie Zucker
5	Mexico kiskadee	Schokolade, Pekannuss, Apfelkuchen
6	Fazenda Matão	Schokoladencreme, Haselnuss, Karamell
7	Willy Wonka	Trinkschokolade, Amarenakirsche
8	Liberica, Honey!	Zuckerwatte, exotische Früchte, verrückt
9	Kenia Crossroads	Dunkle Schokolade, Cassis, dunkler Karamell
10	Wildblume	Geröstete Haselnüsse, Waldhonig, Nougat
11	Berlin, Peru	Schokoladen-Ganache, Himbeere, Zuckerrohr
12	Karma&Co	Schokoladenmousse, Karamell, Orangengelee
13	Rocko Mountain	Erdbeeren, Honigmelone, blumig
14	Ruanda Gisheke	Honigmelone, Fruchtgummi-Apfelringe
15	ALIANÇA	Karamell, Schokolade, Nüsse
16	NENSEBO	Ananas, grüner Apfel, Lakritz

#	Kaffeesorte	Aromen
1	Kambarare estate	Erdbeere, Banane, Zwetschgenkompott
2	Halo Beriti	Earl Grey, Limette, Mandel
3	Kambarare estate	Erdbeere, Banane, Sauerkirschkonfitüre
4	Kambarare estate honey	Pfirsichblüte, Tomate, Johannisbeere
5	Izuba Ryamukona	Rhabarberkompott, Rooibos, Holunder
6	Caturra Lactic	Karamellpopcorn, Birne, Mandel
7	Suke Quto	Himbeere, Grenadine, Rose

Formel für E-Noses

$$\square \Delta^f =$$

$$\square A_S =$$

